

摘 要

以深度神经网络为代表的机器学习依靠其强大的分布拟合能力在大规模监督数据上展示出了自达特茅斯会议以来在人工智能领域的最先进性能，梯度反向传播的提出与并行加速芯片的突破揭开了深度学习革命的序幕。然而，研究社区很快意识到深度学习的性能垄断需要依赖于极为庞大的监督数据，这是一个隐式建模监督数据的过程，也可以规范为信息压缩。与之对比的是，大脑的学习对数据量的依赖并非如此，多数高等动物对新认知概念的掌握仅需几十次甚至几次的反馈刺激即可熟练掌握该项知识，表现出了极高的数据利用效率和认知推理能力。

小样本学习（Few-shot Learning, FSL）旨在尝试打破机器学习与大量监督信号之间的固有依赖。为实现未知分布上的小样本快速泛化，元学习、数据增强、迁移学习等多种范式相继被提出用来解决小样本问题。元学习作为最直觉的范式，由元测试阶段反推规范元训练阶段的学习行为，事实上形成了小样本学习训练-测试上下游范式统一的模式。然而，这种模式并没有展示出先进的性能，本文对该问题进行了深入的集成分析，实证证明了小样本学习训练-测试上下游两阶段割裂的本质，并证明了以模型微调为代表的迁移学习方法能够表现出先进的性能，这与社区此前的共识并不一致。

受到上述分析的启发，本文在分析结论的基础上，继续深入探讨了模型微调迁移学习在小样本问题上的瓶颈，围绕如何高效地实现小样本微调展开研究。首先，小样本微调表现出了对超参数的高度敏感性，且这种敏感性似乎与模型本身更具相关性。本文通过引入集成学习，以集成代替度量式搜索，可以实现更好的迁移性能。其次，以推理的视角观察小样本问题，分析小样本学习过程本身的特点，转而在动态学习过程中向系统注入额外的低频先验，并从傅里叶频域与模型量化双视角证明了算法的有效性。

同时，本文也对大模型时代下的小样本学习进行了思考，结合开放世界学习，重新展望了小样本学习的未来研究，并针对性地给出了若干观点，向社区提供了新的见解。

关键词：小样本学习，元学习，迁移学习，大模型

ABSTRACT

Machine learning, especially deep neural networks, has demonstrated the most advanced performance gain in the field of artificial intelligence with rich annotated data based on its powerful function-fitting ability since the Dartmouth AI Summer Workshop in 1956. The introduction of gradient back-propagation and the breakthrough of parallel acceleration chips opened the prelude to the revolution of deep learning. However, the research community quickly realized that the performance monopoly of deep learning relies on an extremely large amount of annotated data, and it's an implicit process of modeling knowledge and can also be formulated as a process of information compression. In contrast, the learning in the brain does not exhibit such strong dependency on data, and most higher animals can master new cognitive concepts with only a few stimuli feedback, demonstrating efficient data utilization and cognitive reasoning abilities.

Few-shot learning(FSL) aims to break the inherent dependency of machine learning on a large number of supervised signals. To achieve rapid generalization on unknown distributions with limited data, various paradigms such as meta-learning, data augmentation, and transfer learning have been proposed to address the few-shot problem. Meta-learning, as the most intuitive paradigm, involves inferring the learning behavior of the meta-training phase from the meta-testing phase, effectively unifying the meta training-testing paradigm in few-shot learning. However, this paradigm has not demonstrated advanced performance. This thesis provides a comprehensive analysis of this issue and empirically demonstrates the uncorrelation between the meta-training and meta-testing phases and the few-shot problem can be addressed effectively by transfer-learning based methods, particularly model fine-tuning, which can achieve advanced performance, contrary to the previous consensus in the community.

Inspired by the above analysis, the thesis further explores the bottleneck of model fine-tuning in the few-shot learning problem. Based on the analysis of the conclusions, the thesis delves into the efficient implementation of few-shot fine-tuning. Firstly, few-shot fine-tuning exhibits high sensitivity to hyper-parameters, and this sensitivity seems to be more relevant to the model itself. The thesis introduces ensemble learning instead of metric-based search, achieving better transfer performance. Secondly, from the perspective of inference, the thesis profiles the characteristics of few-shot learning and injects

additional low-frequency prior into the dynamic learning system, demonstrating the effectiveness of the proposed algorithm from the perspectives of Fourier and quantization.

Furthermore, the thesis also contemplates few-shot learning in the era of large models. Posed in the view of open-world learning, the thesis looks forward to the future of few-shot learning research and provides some new insights for the community.

Keywords: Few-shot Learning, Meta Learning, Transfer Learning, Few-shot Prompt

目 录

第一章 绪 论	1
1.1 研究对象与背景介绍	1
1.2 小样本学习研究发展与沿革	6
1.2.1 上下游范式的统一与割裂	7
1.2.2 大模型的小样本学习	9
1.3 研究内容与核心贡献	11
1.4 研究思路与文章结构逻辑	12
第二章 小样本学习范式的割裂性分析	13
2.1 从统一到割裂的范式演变	13
2.2 两阶段割裂实证研究	14
2.3 两阶段独立分析	16
2.4 本章小结	18
第三章 高效实现小样本迁移学习	20
3.1 非线性度量增强特征比较	20
3.2 超参数的随机性策略集成	24
3.3 参数高效的模型微调算法	30
3.3.1 频率先验增强的高效模型微调	30
3.3.2 一个量化的视角	35
3.4 本章小结	36
第四章 大模型的提示小样本学习	37
4.1 提示学习与隐式概率建模	37
4.2 SAM 提示粒度一致性	42
4.3 本章小结	49
第五章 总结与展望	50
5.1 全文总结	50
5.2 展望小样本学习研究	51
致 谢	52
参考文献	53

第一章 绪论

1.1 研究对象与背景介绍

自从 1956 年的达特茅斯会议以来，人工智能（Artificial Intelligence, AI）乃至通用人工智能（AGI）一直是研究社区锲而不舍的追求目标。人工智能研究大体可分为三个学派：控制论学派认为智能来源于对于外界的感知和行为，使得智能体在任意复杂环境中达到稳态^[1]；连接主义学派认为智能来源于大量简单单元的高复杂度连接和并行推理^[2]；符号主义学派则秉持智能实际上来源于符号系统的演算系统，是基于某种形式的逻辑^[3]。进入 21 世纪第二个十年，连接主义学派取得了空前的突破，得益于反向传播算法在并行计算加速卡上的成功实现^[4]，连接主义学派的代表性工作“神经网络”带领人工智能社区来到了深度时代，这次浪潮彻底颠覆了人工智能领域，并使得 AI 技术深入到几乎所有行业^[5]。

不过，研究社区很快就发现：深度神经网络有效的关键不仅仅在于更深更宽的网络设计^[6,7]，还在于大量被人工精心标注过的监督数据^[8]。这并不难理解，深度神经网络虽然被证明可以拟合一切^[9]波莱尔可测函数，而统计机器学习的出发点并没有变：根据极大似然参数估计（Maximum Likelihood Estimation, MLE）的渐进无偏性（Asymptotically Unbiased）与渐进高效性（Asymptotically Efficient），设样本数为 n ，最优参数估计 θ ，有：

$$n \rightarrow \infty \Rightarrow E(\hat{\theta}) \rightarrow \theta$$

$$n \rightarrow \infty \Rightarrow \text{Var}(\hat{\theta}) \text{ 为方差最小估计}$$

也就是说，现有的参数估计方法如果想要达到最优估计，就无法摆脱大样本约束。这一点由中心极限定理所定义，当样本数 n 趋向于无穷大时，估计参数与期望参数的标准差 $\sqrt{n}(\hat{\theta} - \theta)$ 收敛于以 0 为均值，以最优参数的费舍信息量的逆 $I(\theta)^{-1}$ 为方差的正态分布，即 $\sqrt{n}(\hat{\theta} - \theta) \sim \mathcal{N}(0, I(\theta)^{-1})$ 。在极限情况下，MLE 将收敛于参数的最小方差，即 $\text{Var}(\hat{\theta}) \geq I(\theta)^{-1}$ ，也称 Cramér Rao 下界。

那么小样本条件下的参数估计，是无法实现的吗？答案是否定的。参数估计效率 $e(\hat{\theta}) = I(\theta)^{-1} \text{Var}(\hat{\theta})^{-1}$ 表示根据观察的随机变量所能估计到参数方差的情况，其中 $I(\theta)^{-1}$ 表示已有随机观测样本 X 携带的未知参数 θ 的信息量。通常情况下，评估 MLE 的结果可以使用估计参数与期望参数的均方误差，假设估计参数为 $\hat{\theta}$ ，

期望参数为 θ ，估计误差可表示为1-1：

$$\begin{aligned}
 MSE(\hat{\theta}, \theta) &= E[(\hat{\theta} - \theta)^2] = E[(\hat{\theta} - E[\hat{\theta}] + E[\hat{\theta}] - \theta)^2] \\
 &= E[(\hat{\theta} - E[\hat{\theta}])^2] + E[(E[\hat{\theta}] - \theta)^2] + \underbrace{E[2(\hat{\theta} - E[\hat{\theta}])(E[\hat{\theta}] - \theta)]}_{\text{此项为0}} \\
 &= Var(\hat{\theta}) + \underbrace{(E[\hat{\theta}] - \theta)^2}_{\text{无偏估计器, 此项为0}} \\
 &= Var(\hat{\theta}) \geq I(\theta)^{-1} \implies e(\hat{\theta}) = \frac{I(\theta)^{-1}}{Var(\hat{\theta})} \leq 1
 \end{aligned} \tag{1-1}$$

那么可以从式1-1看出，参数估计效率与信息量和估计参数的方差有关，而这两个量在某些情况下与样本数 n 有关，例1.1说明了这种情况。

例子 1.1 假设 $X = \{x_1, x_2, \dots, x_n\}$ 是通过独立同分布采样得到的，且服从指数分布，指数分布的均值未知，设为 $\frac{1}{\theta}$ ，求使用 MLE 估计参数 θ 的估计效率。

对数似然函数 $L(X; \theta)$ 以及对数似然函数的一阶、二阶微分表示为：

$$\begin{aligned}
 \log(L(X; \theta)) &= \log\left(\prod_{k=1}^n f(x_k; \theta)\right) = \log\left(\prod_{k=1}^n \theta \exp(-\theta x_k)\right) \\
 &= \log(\theta^n \exp(-\theta \sum_{k=1}^n x_k)) \\
 &= n \log(\theta) - \theta \sum_{k=1}^n x_k \\
 \frac{\partial \log(L(X; \theta))}{\partial \theta} &= n\theta^{-1} - \sum_{k=1}^n x_k \\
 \frac{\partial^2 \log(L(X; \theta))}{\partial \theta^2} &= -n\theta^{-2}
 \end{aligned}$$

因此，考虑到上式为凸函数，根据一阶导可得参数 θ 的估计表达式为：

$$\hat{\theta} = \frac{n}{\sum_{k=1}^n x_k}$$

估计参数的期望、方差、期望参数的 Fisher 信息量和估计效率表示为：

$$\begin{aligned}
 E[\hat{\theta}] &= \frac{n}{n-1} \theta & Var[\hat{\theta}] &= \frac{\theta^2 n^2}{(n-1)^2(n-2)} \\
 I(\theta) &= -\frac{\partial^2 \log(L(X; \theta))}{\partial \theta^2} = n\theta^{-2} \\
 e(\theta) &= \frac{I(\theta)^{-1}}{Var(\hat{\theta})} = \frac{(n-1)^2(n-2)}{n^3} \left(\lim_{n \rightarrow \infty} e(\theta) = 1 \right)
 \end{aligned}$$

可以计算出，参数估计效率 $e(\theta)$ 在 $[2, +\infty]$ 上单调递增，并且极限为 1，而 1 和 2 是它的两个零点，且 n 在正整数域，所以在这种情况下，MLE 并不是指数分布均值的有效估计器，并且估计效率会随着样本数 n 的增加而逐渐收敛于 1。

从例1.1可以观察到，样本数 n 与参数估计效率之间存在着某种关系，即样本数越多，参数估计效率越高。特别说明的是，这仅仅针对 MLE 是非有效估计器的情况，实际上对于 MLE 是无偏估计的场景中（例如高斯分布的均值参数估计），MLE 的估计期望等于真实参数，此时估计效率始终为 1，与样本数无关。MLE 具有渐进正态性，其渐进性质保证了在有限样本数量下的估计参数效率，并且任何数据集样本数量 n 都不能趋向于无穷大，那么尽可能提高参数估计效率即可。例如，当正态分布方差已知且被估计参数为分布的中值时，仅需 3 个样本，即可达到 74% 的参数估计效率^[10]。小样本参数估计在实际场景中也就是利用渐进性质实现样本量、估计效率和模型能力的权衡。

回到机器学习的本身，相比于高等动物的学习方式，机器学习显得过度依赖于数据驱动。毕竟机器学习的本质是统计学习，而高等动物则可以借助想象、长短期记忆、因果推理等高阶认知能力，快速地在小样本环境下学习新的知识。例如，啮齿类动物可以在几十次的尝试下，通过 Y 迷宫测试，认识到哪扇门背后存在食物^[11]。

直接期望机器学习模型从头学习小样本新概念是没有意义的，也是不太现实的。李飞飞等人^[12]第一次提出小样本学习问题时，即拒绝了这一假设。他们认为，既然人类可以从长期记忆（经验）和因果推理中快速获得新知识，那么机器学习模型同样可以参考人类学习的特点：从先前已经学到的类别知识中获得帮助，而先前知识与新知识之间不必存在相关性。后续工作在规范小样本图像分类问题时，仍然肯定并延续了这种思想，即机器学习模型需要从训练数据集中获得足够的元知识，并在测试数据集中借助已获得的知识实现快速泛化。需要明确的是，测试数据集理论上应是开放世界的，虽然在算法基准中限定了测试数据集的范围。从参数估计的角度来看，相对于随机初始化的参数 $\hat{\theta}$ ，已经学习到一小部分开放世界知识的神经网络参数 $\hat{\theta}'$ 显然可以从相同的样本数中获得更优的参数估计（期望分布是固定的），这一点奠定了小样本学习范式的基本原则。

本文参照 Vinyals 等人^[13]的定义，给出小样本学习^①的标准定义，另外需要强调的是小样本分类问题研究并不为了解决分类问题，而是以此为入口研究小样本问题，本文中在分类问题上的结论在其他领域（分割、检测）也有体现。

小样本学习旨在通过训练数据分布 $\mathcal{D}_t$ 借助训练时算法 $\mathcal{F}_t$ 学习得到以 θ 参数化的模型 $\mathcal{G}_\theta$ ，这里的训练时算法可以是任意类型算法。当测试时，假设存在一个测试时数据分布 $\mathcal{D}_{te}$ ，从该测试分布中随机采样出 n 个样本 $\{d_i\}_{i=1\dots n}$ 构成一个任务 $\mathcal{T}$ ，在 n 个样本中，其中的 m 个样本 $\{d_j\}_{j=1\dots m}$ 具备对应的标签 $\{l_j\}_{j=1\dots m}$ 并构成

① 需要特别说明的是，小样本图像分类问题是小样本学习的试金石，本文所提及小样本学习如未特别说明，均指的是小样本图像分类问题。

任务 $\mathcal{T}$ 支持集 $\mathcal{S}_{\mathcal{T}}$ ，而另外 $n - m$ 个样本构成任务 $\mathcal{T}$ 的查询集 $\mathcal{S}_Q$ 。模型 $\mathcal{G}_{\theta}$ 通过测试时算法 $\mathcal{F}_{te}$ 在支持集 $\mathcal{S}_{\mathcal{T}}$ 上快速适应，并对查询集 $\mathcal{S}_Q$ 中的数据进行推理。需要再次说明的是， $\mathcal{D}_{te}$ 理论上应为开放域，且不能和 $\mathcal{D}_{tr}$ 存在重叠，因此 $\mathcal{D}_{tr}$ 与 $\mathcal{D}_{te}$ 不仅存在类别差异、域差异、粒度差异，甚至存在任务类型差异（广义小样本学习问题，模型为通用编码器，在每个测试任务 $\mathcal{T}$ 上学习对应的任务头）。小样本问题示意图见图1-1。




图 1-1 小样本问题示意图

在算法设计中，往往模型 $\mathcal{G}$ 会在训练数据集上进行不限于元学习、监督学习、自监督学习等多种类型的训练，而实际上，模型可以在任何可获得的数据域上进行训练，只要保证 $\mathcal{D}_{tr}$ 和 $\mathcal{D}_{te}$ 之间不存在重叠即可。为了解决小样本问题，首先要明确小样本学习的难点在哪里。正如前文分析，小样本量这一特点导致了参数估计的两难窘境，如何减缓或者绕过参数估计效率和样本量之间的两难权衡是指导学习范式的重要考虑。

元学习，从任务中学习“如何学习的能力”。

一种很符合直觉的方案是从测试阶段倒推训练阶段的学习形式。由于小样本学习测试阶段是以任务为输入的，考验模型的主要能力是快速适应新任务的能力，这里的新任务包括但不限于新概念、新域等。那么在训练阶段，根据深度学习的一致性原则^[14]，如果训练模型具备这种快速适应的能力，那么在测试时，学习系统并没有发生改变，这种训练-测试的一致性可以带来可预期的性能。这种范式被称为元学习（Learning to Learn），即学会如何学习这件事。模型在训练阶段在大量由训练数据集构成的任务集上训练，对于每个任务，模型都要快速适应支持集的样本，然后对查询集做出预测并在查询集上计算损失函数，从而回传梯度更新模型。这种学习范式很符合直觉：既然测试时域不可知，那么授人以鱼不如授人以渔，如果模型学会“学习”这个能力，那么也就可以做到融汇贯通了。从参数估计的角度来看，元学习这种范式成功地把样本类型从监督实例转换为了任务，训

训练集上的任务排列组合远远多于训练集本有的监督实例，这可能有助于提高在训练数据集上的参数估计效率。

迁移学习，打破训练测试一致性。

在小样本浪潮的最近几年，迁移学习范式逐渐占据主流。该范式不再要求训练和测试学习范式的一致性，而是要求训练阶段提供的预训练模型越强大越好，而测试时采用最先进的迁移学习技术在测试任务上的支持集上微调即可。这种范式虽然直观，但仍面临着诸多问题，比如超参数选择、测试开销过大等。迁移学习范式为小样本提供了尽可能强大的预训练模型，这将有助于在测试阶段模型在支持集上获得更高的参数估计效率。

传统意义上，解决小样本问题还有多种方案。如最直接的数据增强方案：借助扩散模型在支持集上扩增数据^[15]等等，但本文将只从最主流的发展沿革入手，以元学习范式上下游训练-测试统一和割裂为入口，自然过渡到以模型微调为手段的迁移学习范式上。此外，随着基础模型领域的进展，小样本学习的形式也发生了变化，如基于 CLIP^[16] 模型的提示学习^[17]、基于大语言模型的上下文学习^[18]等，这些变化在本文中都将进行讨论。

回顾小样本学习的提出背景，本文认为它试图解决三个问题：

1. 作为实现开放世界学习的第二环节，小样本学习充当着实现通用人工智能的试金石。

开放世界学习^[19]包括分布外样本检测（Out-of-Distribution Detection, OOD）、小样本学习与持续学习（Continuous Learning）。设想一个在开放世界中的智能体，当遇到没有见过的新概念时，首先需要检测出这属于分布外样本，其次通过主动学习技术或搜索技术获得分布外样本的概念标签从而进行小样本学习，与此同时，不能遗忘已有的知识，即持续学习。因此，在整个开放世界学习过程中，小样本学习往往和持续学习是同时发生的。而小样本持续学习的进行，又会给下一次的分布外检测带来更大的困难，因为 OOD 检测作为一个理论上不可能彻底解决的问题，严重依赖于分布内（In-Distribution）样本的学习从而约束模型的决策边界，而分布内样本随着开放世界学习的进行，会有越来越多的小样本知识加入，这给 OOD 检测带来了本质上的困难。

2. 研究社区希望通过小样本学习窥探机器学习的动力学本质，而后者至今仍未能有足够清晰的方法论。

小样本学习与普遍意义上的机器学习问题在形式上没有本质的区别，任何监督学习问题加上小样本条件都属于小样本学习的研究范畴。这是一个从“Many-shot”到“Few-shot”的退化过程，而在退化过程中，小样本到底带来了什

么本质的问题：小样本条件的引入，是否会导致学习过程的本质区别？这一点社区进行了一些探索^[20]，但目前仍不清楚。本文也将从该点出发，尝试从微调视角分析小样本学习的本质问题。

3. 工业中存在大量数据无法大量采集、采集成本高的场景。

实际应用场景中，许多场景难以采集监督数据，导致了训练集的严重缺乏。例如，在缺陷检测、危险识别任务中，监督数据客观上就很难获得，这促使了小样本学习在闭集场景中的广泛应用。

1.2 小样本学习研究发展与沿革

在神经网络兴起的第一个十年，小样本问题走过了从元学习范式到迁移学习范式的转变。在本节中本文将探讨范式转变的原因，也将指出正是因为这种转变，社区对小样本学习产生了新的见解。除了元学习和迁移学习范式，随着基础模型和大模型的发展，小样本学习在新的阶段也体现出了不同的学习形式。2020年，CLIP模型的发布指示了一种新的视觉语言基础模型的训练范式，各种视觉基础模型^[21-24]也相应的被提出。视觉基础模型与以往的通用视觉编码器（如ViT）不同，由于基础模型在训练时使用了远超过ImageNet量级的数据，并且模型规模也比较大，往往认为它的预训练知识已经足够丰富，因此在面对下游任务时可以不再需要让上游模型适应下游数据，而是使下游数据适应上游模型，与模型预训练时的任务类型做对齐，比如提示前缀学习（Prefix Tuning）^[17,25-28]，与模型微调等高消耗的方式相比，提示学习（Prompt Tuning）可以把适应下游任务的开销控制在非常小的程度上。除了视觉和多模态基础模型，大语言生成模型的发展也让小样本学习迎来了一个新形式。2022年底，OpenAI发布了GPT3^[18]的迭代产品：ChatGPT，宣告了大型语言模型在自然语言处理领域的颠覆性革新。随后一年，基于数据的扩展（Scale-up）思想和基于Transformer模型的生成式结构（如各类Meta Transformer^[29-31]、Diffusion Transformer^[32]）随后逐渐统一了包括音频、2D视觉、视频在内的多个领域，并逐步渗透进多模态领域。而在GPT3^[18]中，模型的涌现能力（Emergence Ability）被明确定义，小样本学习迎来了新的范式，即上下文学习（In-Context Learning）。传统小样本学习中的支持集变成了小样本提示（Few-shot Prompt），而大模型可以根据小样本提示快速掌握该任务的特点，从而激发（也可能是获取）在任务上所需的知识，这一过程不需要任何梯度下降和模型更新，是小样本学习在大模型时代的代表性特点之一。^①

在本节中，1.2.1中叙述小样本的元学习和迁移学习范式，主要从训练-测试上

^① 在本文中，除非特殊说明，否则大模型均指代基础模型和生成大模型两类。




图 1-2 小样本问题部分算法发展沿革图，可以看出解决范式从元学习到非元学习算法的转变，以及大模型小样本提示的曙光

下游形式的统一和割裂角度来观察这两类范式。1.2.2中叙述小样本学习在大模型时代下的表现形式，即提示学习与上下文学习。

1.2.1 上下游范式的统一与割裂

小样本问题走过了从元学习范式到非元学习范式的转变。在本节中，从分别介绍元学习的三种常见算法分类到非元学习算法（如模型微调等），并描绘出元学习-非元学习的历史发展沿革^①，同时对训练-测试两阶段统一与割裂作出简要定义与说明。图1-2是小样本问题从元学习范式到非元学习范式的发展时间线。从中已经可以看出小样本学习的三个历史阶段：元学习、非元学习与大模型，而研究社区目前正处于第三个阶段中。

在 2015-2019 年之间，社区主要从如何设计更能快速适应新任务的元学习算法入手。从元学习中又可分为三类常见的算法，分别是优化、度量和模型角度来考虑设计元学习算法。图1-3^②示意了元学习基本的流程，元学习旨在学习一个元学习器（Meta Learner）并在输入新任务时，元学习器可以快速借助支持集学习到新概念，生成针对于该任务的学习器（Learner），也就是说元学习器掌握了如何学习的能力而不是某个任务的能力。

基于度量的元学习方法旨在编码出任务中支持集和查询集中的所有样本后，利用其在特征空间中的度量关系进行分类。因此，该类方法大部分工作都在寻求

① 图1-2源自 NeurIPS 2022 Tutorial: The Role of Meta-learning for Few-shot Learning(by Eleni Triantafillou)

② 图1-3源自 Ji Zhang's talk on Meta Learning




图 1-3 元学习概念示意图

学习一个好的上游编码器与下游分类器。Siamese Network^[33] 通过学习一个双分支网络来对齐支持集中的图像编码与查询集中的图像编码，奠定了基于度量比较的小样本算法的雏形，但此方法并非元学习方法；MatchingNet^[13] 则重新标准定义了小样本问题，并将问题拓展到广义的“Few-shot”而不重点关注于“One-shot”，通过一个编码器神经网络将图像编码并通过一对一的比较查询集和支持集中的图像对查询集图像进行分类，分类器基本等价于 K-近邻分类器，此外该工作还提出了难度更大的 MiniImagenet 作为新的基准，指导了未来五年的小样本研究。ProtoNet^[34] 考虑到 MatchingNet 度量比较的计算复杂度关于支持集样本数量 m 是线性复杂度 $\mathcal{O}(m)$ ，提出了将类中心而不是所有类样本作为该类的比较对象的度量对比方式，将单一查询集样本的计算复杂度降低为 $\mathcal{O}(1)$ ，成为了度量元学习的基线；RelationNet^[35] 则认为度量空间限定在欧式空间中可能存在局限，因此训练了一个神经网络来表示两个特征的相似度。

基于优化的元学习方法则为每个新任务都学习一个参数化分类器，MAML^[36] 作为该类元学习方法的开山之作，将元学习的思想非常显式地应用起来。MAML 试图学习这样一个模型初始化参数：该初始化参数在测试阶段的任何一个任务上，都可以在几次梯度下降之后到达最优解。考虑到 MAML 的过拟合风险与过高的计算负担，CAVIA^[37] 提出仅通过元学习训练少量模型参数，减小计算负担。MAML++^[38] 与 Ye 等人^[39] 工作通过对 MAML 的深入理解给出了相应的 MAML 训练方法，使得 MAML 类算法的效果进一步得到了提升。优化方面另一个很出色的代表工作是 LSTM-Meta-Learner^[40]，与 MAML 学习一个好的网络初始化不

同，其直接将优化过程当作需要被元学习的目标，直接去学习优化过程中的超参数（如学习率、衰减因子等），这使得模型的学习变得更加灵活。

基于模型的元学习方法不是元学习方法解决小样本问题的主流方法，但是其方法原则充分体现了元学习的初衷。之所以称之为基于模型的元学习方法，是因为该类元学习方法直接去预测新任务上的模型。它们基于这样一种假设：既然元学习是学习如何学习一个任务，那么学习一个任务最关键的就是根据任务数据特点对模型参数进行微调得到适合于该任务的参数，为什么不直接由元学习器生成任务特定参数呢？Meta Network^[41]根据这个思路，并结合人类的快速和慢速思考模式^[42]，将模型参数分为快慢参数，快参数由元学习器直接生成，慢参数由优化器按照梯度下降得到，其中我们可以认为元学习器中实际上包含着以往的知识。这一思路并没有在当时得到足够的重视，但近些时候，Patacchiola 等人^[43]提出的 UpperCASE 方法再一次实践了这个思路，并将小样本学习微调方法的帕累托边界推向了新的极限。另一个直观的想法是把知识显式的存储在计算机内存和参数化模型中，Santoro 等人^[44]利用长短期记忆网络（Long-Short Memory Network）配合知识的内存数据结构存储，借助神经图灵机的读写机制，充分发挥了基于模型存储知识的作用。

从上面三种元学习算法中可以看出，元学习保持了一种训练与测试在形式上的统一。元学习在训练阶段的形式和在测试阶段的形式保持一致，这种理念符合机器学习中的一致性原则，优雅且直觉。但随着 2019 年 Chen 等人^[45]对小样本领域的分析性工作，这种一致性的先入为主被打破，社区发现很普通的非元学习方法也可以获得相当好的性能，比如一个好的预训练编码器配合逻辑斯蒂回归分类器。而这种非元学习方法重新思考了训练阶段的目标，抛弃了训练-测试一致性。简单来说，训练阶段的目标是为了获得一个足够具有区分性的编码器，而无需关心其通过什么训练方法得到。同时期的几项工作^[46,47]也从编码质量和数据等角度支持了 Chen 等人的观点。随后，在 2019-2021 年，一大批混合元学习与非元学习、纯非元学习方法^[48-54]开始出现，社区同时也开始思考非元学习方法与元学习方法的本质区别^[55]。

1.2.2 大模型的小样本学习

2022 年中，OpenAI 发布了 GPT3^[18]，在这项工作中发现了当一个足够大的语言模型在足够多的语料库上进行训练之后，大模型产生了涌现能力^[56]，即小模型上不会出现且外插小模型性能也无法预测的性能突变。涌现能力的一个体现就是模型具备了仅靠少量的提示样本，即可在完全不需要梯度下降的条件下，推理出

新问题的答案。正是因为此，GPT3 的论文标题被定为了“语言模型也同样是小样本学习器”，反映了上下文学习的雏形。

首先，本文需要对大模型的范围作出说明。本文所指大模型，需要从两个角度来理解。第一，是从自然语言社区引申出的大型自然语言/视觉/多模态生成模型^①，这类模型的特点是基于“下一个 Token 预测”的方式进行训练和推理，因此要求数据组织为序列建模的形式。生成模型的任务范式可通过图1-4示意。第二，是从多模态或视觉领域引申出来的基础模型，如 CLIP [16]、ALIGN [57]、SAM [21]、DINOv2 [58] 等。这些基础模型虽然同样具备强大的表征能力与零样本能力，但是其预训练方式并不生成的，例如 CLIP 的训练是依靠图像与自然语言的对齐来进行，SAM 的训练依靠大量无语义掩码图像，这些都不属于生成模型的范畴。但不可否认，由于模型复杂度的大幅提高和远胜于 ImageNet 量级的数据，本文又很难将其与在 ImageNet 上预训练的各种 ViT 模型并列，因此将其称为基础模型，并在本文语境下归纳到大模型范畴。




图 1-4 小样本提示示意图，上方是大型生成语言模型示例，下方为大型生成视觉模型示例 [59]

本文在这里分别对基础模型和大语言/视觉生成模型的小样本学习形式做出简述。对于基础模型来说，由于其推理方式上并没有与传统预训练的 ViT 模型有本质的区别，所以依旧可以看作特征编码器。唯独不同的是，由于训练数据极度丰富，可以认为这些基础模型掌握了一定程度的世界知识，因此常用于传统预训练模型的适配器微调（Adapter）、参数有效微调（Parameter Efficient Fine-tuning,

① 请读者注意生成模型与生成式模型的区别，生成式模型是相对于判别式模型而言的，生成式模型建模的是变量的联合分布，而生成模型只是一个泛概念，如 GPT3 实际上属于判别式生成模型。

PEFT)、全量微调等方式通常不再是基础模型应用到下游任务的首选。基础模型的学习方式从传统的模型适应下游任务转变为了下游任务适配基础模型，例如 CLIP 模型、SAM 模型可以通过提示微调，使得下游任务类型适配上游模型的预训练任务类型，即将下游任务数据映射到上游模型的知识空间中去，将微调参数转化为了优化数据前缀项，其期望新的数据分布可以通过更改其额外的增量前缀满足模型预训练时的数据分布，这不需要模型参数上的任何更新，但这类模型目前不存在涌现现象。

对于大型生成模型来说，传统的支持集转变为了小样本提示，即原先支持集的数据-标签对作为提示输入给大模型，大模型可以根据一个或者多个数据-标签对快速掌握如何解决这项新任务的能力，形象化的解释见图1-4。当然，大模型的提示不一定非得要是“Few-shot Prompt^[60]”，也有许多零样本提示^[61]方法，因此小样本提示并非大模型提示工程的唯一选择。

1.3 研究内容与核心贡献

本论文研究内容重点集中在从模型微调视角下研究小样本图像分类问题，即如何在新数据域的小样本任务上良好的实现微调。由于小样本任务的特殊性，支持集中的样本数非常少所以存在着明显的偏差。因此微调中，如何实现微调的泛化和鲁棒性是至关重要的。这里的泛化指的是模型能够仅靠支持集小样本掌握（在丰富样本条件下）相同的概念知识；鲁棒性指的是即便相同概念的支持集发生了变化，模型依然能够掌握不变的概念知识。

研究分为两步，第一步集成分析小样本分类问题的训练和测试阶段的性质，得出二者割裂性的观察，并分别对两个阶段进行分析；第二步聚焦在适应阶段，即如何对预训练好的模型实现在小样本任务上好的迁移。具体而言，第一步首先需要对小样本分类问题有一个系统性的认识，观察一个研究对象可以有多种角度，而本文将从训练、适应两阶段及其关系入手，明确两阶段是否割裂关系，并分别单独对两阶段中影响小样本性能的方面做深入分析；在第一步的基础上，以第一步发现性结论为前提，聚焦在适应阶段对小样本任务支持集的参数微调为要点，侧重研究超参数敏感性和特异性微调方法，在主流数据集上验证算法的有效性。

第一步在训练阶段的结论可以分析出解决小样本问题需要尽可能强大的上游模型的观点。当下社区已经全面转向了大模型，而恰恰小样本社区与大模型社区走到了殊途同归的道路上。本文自然地将小样本学习在大模型的框架下考虑，做出了一些富有建设性的分析，并给出了一个基础模型提示学习的案例研究。综上所述，本文拟解决的关键性问题有：

1. 小样本分类任务两阶段割裂性证明及两阶段性质分析
2. 小样本分类问题适应阶段高效参数微调方法
3. 大模型的小样本学习

1.4 研究思路与文章结构逻辑

本文的研究思路从重新思考元学习于小样本的意义开始，探究为什么元学习不能实现好的小样本性能以及为什么不同的范式在不同的数据集基准上表现出了不同的结果，进而探究小样本学习中训练与测试两阶段的统一与割裂，并根据大量的实证研究给出了证明；进一步地，既然证明两阶段是割裂的，那么可以对两阶段进行针对性分析，从而在两个阶段都得出了一些有价值的观察；紧接着，从测试阶段入手，对小样本条件引入的超参数敏感问题、高效鲁棒微调方法等方面进行了探究，并从超参数集成与高效微调手段入手，提高小样本微调方法的性能；最后，从训练阶段得出的结论得到启发，与大模型领域的最新进展结合，以大模型的视角观察小样本问题，提出了在大模型时代下关于小样本学习的若干思考，并给出了一个提示学习调整基础模型的案例研究。基于此，文章的结构逻辑如下：

第一章重点介绍了小样本学习的背景与定义，从学习范式和参数估计角度简述了小样本问题，然后按照小样本学习的发展沿革从元学习、迁移学习到小样本提示，回顾了小样本学习近十年的发展历程。本章非常重要，对于理解后文各章的逻辑关系起到了提纲挈领的作用。

第二章作为中枢性章节，是第三章与第四章的父节点。在本章中重新审视了小样本分类问题的经典元学习范式，完备地分析了范式的统一与割裂与实证证明，并列举了一些两阶段分析结论，为下文的三、四章奠定了理论性基础。

第三章从测试阶段得出的见解出发，首先分析了超参数敏感性的问题，从超参数分析中观察到知识偏移的现象，从而自然引出低频先验增强的高效鲁棒模型微调算法，并从傅里叶与量化双视角分析其有效的原因。

第四章从训练阶段得出的见解出发，在大模型的视角下观察小样本学习。首先对小样本在基础模型和大型生成模型中的形式进行建模，并对大模型时代下的小样本学习提出了几点思考，同时给出了一个基础视觉模型的提示一致性研究案例。

第五章对全文做了总结，同时在最后提出了关于小样本问题的未来发展方向

的几点思考，是作者在当下看待小样本学习的核心观点。

第二章 小样本学习范式的割裂性分析

2.1 从统一到割裂的范式演变

小样本问题本身是一个传统的机器学习问题，因此很自然地，能够将小样本问题分为训练阶段和测试阶段（或适应阶段）。训练阶段负责获得一个可供调整的模型，测试阶段负责将训练阶段的模型适应到新的任务上。元学习是解决小样本问题的一个很自然的想法：以一种学会学习的方式训练模型并在新任务上发挥这种能力，学会新任务上需要的能力。许多工作延续了这种思想 [13,34,36]，得到了不错的结果。Banayeeanzade 等人 [62] 发现，虽然元学习训练旨在提供一个更好的可供快速适应新任务的模型，但是其表征空间却比普通的监督学习训练（如以交叉熵损失函数训练）的模型在类别表征上更加紧密，这被认为是元学习可以取得还不错的小样本结果的原因之一，这也能够很好地解释为什么元学习在跨域问题上表现很差。所以元学习训练过程仍旧在掌握区分类别的知识，这与普通监督预训练一致。虽然如此，元学习显然不是一种迁移学习技术，元学习更像是在触发预训练知识，而迁移学习则是显式的知识传递。

一个意外的发现出现在 Chen 等人 [45] 的工作中，他们发现一个经过普通的监督预训练的网络，用一个非常简单的适应方法（如逻辑斯蒂回归）就可以获得很好的性能，这比几乎所有元学习方法都要好。普通的监督预训练方法并不会为了小样本问题而专门设计，这个发现暗示着似乎训练阶段的方法和测试阶段的方法似乎是分离的，即不需要考虑训练阶段用什么方法，只需要专注于每个阶段自己的方法设计就可以。迁移学习最开始并没有受到重视的原因是考虑到在小样本上严重的过拟合问题，当然这也实际的发生。然而在下文，本文会证明这种对于迁移学习的认识偏差来源于对于优化过程的不充分讨论2.3，在做了一些关键性调整（如超参数分离）之后，本文发现迁移学习可以在几乎所有实验设置上达到最佳性能。

元学习在形式上统一了训练和测试，而非元学习范式往往是不统一。那么上下游训练-测试统一是否是好的？这启发社区重新思考元学习对于小样本问题的价值，以及元学习的本质，以及元学习的训练方法为什么没有产生良好的性能表现。元学习似乎过度定义了小样本问题，社区却轻易地忽视了简单的迁移学习范式。在回答这个问题之前，首先需要证明训练和测试两阶段是否是完全割裂的，这里割裂的定义是任何一个测试算法在经过不同训练方法上训练得到的模型上的性能排序都与训练算法无关，而只与测试算法本身有关。这一点很难从理论上证明，但

本文通过大量的实证实验给出了确切的结论：小样本学习的训练和测试两阶段是完全割裂的。这种割裂性非常有益，不仅可以分别考虑各个阶段的算法而无需顾及另一个阶段，还能够单独对每个阶段进行分析。

2.2 两阶段割裂实证研究

首先，本文对割裂进行正式的形式化定义。给定一个训练算法集合 $\mathcal{M}^{train} = \mathcal{A}^{\{train_i\}}_{i=1}^{m_1}$ 和一个测试算法集合 $\mathcal{M}^{adapt} = \mathcal{A}^{\{adapt_i\}}_{i=1}^{m_2}$ ，定义 $\mathcal{M}^{train}$ 与 $\mathcal{M}^{adapt}$ 完全不相关如果改变 $\mathcal{M}^{train}$ 中的算法， $\mathcal{M}^{adapt}$ 中的算法结果排序不受改变，反之亦然。

定义 2.1 如果对于所有的 $i \in [m_2]$,

$$\begin{aligned} \text{Avg}(\mathcal{A}_a^{train}, \mathcal{A}_i^{adapt}) - \text{CI}(\mathcal{A}_a^{train}, \mathcal{A}_i^{adapt}) < \\ \text{Avg}(\mathcal{A}_b^{train}, \mathcal{A}_i^{adapt}) + \text{CI}(\mathcal{A}_b^{train}, \mathcal{A}_i^{adapt}) \end{aligned} \quad (2-1)$$

那么两个训练算法 $\mathcal{A}_a^{train}$ 和 $\mathcal{A}_b^{train}$ 满足偏序关系 $\mathcal{A}_a^{train} \preceq \mathcal{A}_b^{train}$ 。需要说明的是，不等式成立的条件是存在 $\mathcal{A}_a^{train}$ 的置信区间的值，小于 $\mathcal{A}_b^{train}$ 在置信区间的某个值时即可成立。另外，该偏序关系可能不满足传递性，即如果有 $\mathcal{A}_1^{train} \preceq \mathcal{A}_2^{train}$ 和 $\mathcal{A}_2^{train} \preceq \mathcal{A}_3^{train}$ ，那么 $\mathcal{A}_1^{train} \preceq \mathcal{A}_3^{train}$ 可能不满足。但实际上，在实验中，这种不满足传递性的现象并没有出现，因此可以认为目前的实验结果中，是满足传递性的。

定义 2.2 $\mathcal{M}^{train}$ 和 $\mathcal{M}^{adapt}$ 是割裂的，如果它们是在定义2.1上的有序集合。

本文在训练阶段选取了包含元学习算法和非元学习算法在内的数十种算法。对于元学习算法，使用了 MAML [36]、ProtoNet [34]、MatchingNet [13]、MetaOpt [63]、FEAT [64]、DeepEMD [65] 和 MetaBaseline [50]。非元学习算法包括监督算法交叉熵基线 [45]、COS [66]、S2M2 [67]、IER [54]、BiT [68]、Exemplar-v2 [69]、DeiT [70]，自监督算法 DINO [23]、MoCo-v2 [71] 和自然语言监督对比学习算法 CLIP [16]。

在测试阶段，本文也选取了元学习方法 MatchingNet [13]、MetaOpt [63]、Nearest Centroid Classifier(PN) [34]，Finetune(MAML) [36] 和非元学习方法逻辑斯蒂回归 [46]、URL [72]、Cosine 分类器 [45]，还有仅测试时段算法 TSA [73] 和 eTT [74]。

关于实验测试阶段中所用的数据集，本文选择了 Meta-Dataset [47] 与 MiniImageNet [13] 两个在小样本问题上最常用的数据集基准。Meta-Dataset 包含 10 个来自不同视觉域的数据集，其中 ImageNet [8] 被从数据中去除以防止出现标签泄露。另外本文还用了 MiniImageNet 基准，该数据集包含了来自 ImageNet 的 100 个类别，每个类别随机采样 600 个样本，其中训练部分包含 64 个类别，测试部分包含 20 个类别，验证部分包含 16 个类别。本文同样采用了一部分训练算法在 MiniImageNet

表 2-1 在 Meta-Dataset 上测试的算法组合小样本性能 5-way 5-shot 结果。所有的评估任务采样自 Meta-Dataset（除了 ImageNet），在其中的 9 个数据集上每个数据集上采样了 2000 个任务，并报告在 9 个数据上的平均性能与平均 95% 置信区间。算法按照定义的偏序从左至右、从上至下排序。* 为训练算法使用直推式批归一化 [75]，这会造成更好的但不公平的算法比较。TSA 和 eTT 是特定结构微调算法，其中 TSA 适用于 CNN 结构，而 eTT 适用于 ViT 结构

训练算法	训练数据集	架构	测试算法							
			MatchingNet	MetaOpt	NCC	LR	URL	CC	TSA/eTT†	Finetune
PN	miniImageNet	Conv-4	48.54±0.4	49.84±0.4	51.38±0.4	51.65±0.4	51.82±0.4	51.56±0.4	58.08±0.4	60.88±0.4
MAML*	miniImageNet	Conv-4	53.71±0.4	53.69±0.4	55.01±0.4	55.03±0.4	55.66±0.4	55.63±0.4	62.80±0.4	64.87±0.4
CE	miniImageNet	Conv-4	54.68±0.4	56.79±0.4	58.54±0.4	58.26±0.4	59.63±0.4	59.20±0.5	64.14±0.4	65.12±0.4
MatchingNet	miniImageNet	ResNet-12	55.62±0.4	57.20±0.4	58.91±0.4	58.99±0.4	61.20±0.4	60.50±0.4	64.88±0.4	67.93±0.4
MAML*	miniImageNet	ResNet-12	58.42±0.4	58.52±0.4	59.65±0.4	60.04±0.4	60.38±0.4	60.50±0.4	71.15±0.4	73.13±0.4
PN	miniImageNet	ResNet-12	60.19±0.4	61.70±0.4	63.71±0.4	64.46±0.4	65.64±0.4	65.76±0.4	70.44±0.4	74.23±0.4
MetaOpt	miniImageNet	ResNet-12	62.06±0.4	63.94±0.4	65.81±0.4	66.03±0.4	67.47±0.4	67.24±0.4	72.07±0.4	74.96±0.4
DeepEMD	miniImageNet	ResNet-12	62.67±0.4	64.15±0.4	66.14±0.4	66.14±0.4	68.66±0.4	69.76±0.4	74.21±0.4	74.83±0.4
CE	miniImageNet	ResNet-12	63.27±0.4	64.91±0.4	66.96±0.4	67.14±0.4	69.78±0.4	69.52±0.4	74.30±0.4	74.89±0.4
Meta-Baseline	miniImageNet	ResNet-12	63.25±0.4	65.02±0.4	67.28±0.4	67.56±0.4	69.84±0.4	69.76±0.4	73.94±0.4	75.04±0.4
COS	miniImageNet	ResNet-12	63.99±0.4	66.09±0.4	68.31±0.4	69.26±0.4	70.71±0.4	71.03±0.4	75.10±0.4	75.68±0.4
PN	ImageNet	ResNet-50	63.68±0.4	65.79±0.4	68.40±0.4	68.87±0.4	69.69±0.4	70.81±0.4	74.15±0.4	78.42±0.4
S2M2	miniImageNet	WRN-28-10	64.41±0.4	66.59±0.4	68.67±0.4	69.16±0.4	70.88±0.4	71.38±0.4	74.94±0.4	76.89±0.4
FEAT	miniImageNet	ResNet-12	65.42±0.4	67.15±0.4	69.06±0.4	69.21±0.4	71.24±0.4	72.07±0.4	75.99±0.4	76.83±0.4
IER	miniImageNet	ResNet-12	65.37±0.4	67.31±0.4	69.30±0.4	70.01±0.4	72.48±0.4	72.85±0.4	76.70±0.4	77.54±0.4
Moco v2	ImageNet	ResNet-50	65.47±0.5	68.63±0.4	71.05±0.4	71.49±0.4	74.46±0.4	74.57±0.4	79.70±0.4	79.98±0.4
Exemplar v2	ImageNet	ResNet-50	67.70±0.5	70.07±0.4	72.55±0.4	72.93±0.4	75.26±0.4	76.83±0.4	80.22±0.4	81.75±0.4
DINO	ImageNet	ResNet-50	73.97±0.4	76.45±0.4	78.30±0.4	78.72±0.4	80.73±0.4	81.05±0.4	83.64±0.4	83.20±0.4
CE	ImageNet	ResNet-50	74.75±0.4	76.94±0.4	78.96±0.4	79.57±0.4	80.89±0.4	81.51±0.4	84.07±0.4	84.92±0.4
BiT-S	ImageNet	ResNet-50	75.44±0.4	77.86±0.4	79.84±0.4	79.97±0.4	81.79±0.4	81.91±0.4	84.84±0.3	86.40±0.3
CE	ImageNet	Swin-B	75.17±0.4	77.81±0.4	80.06±0.4	81.04±0.4	82.55±0.4	82.46±0.4	-	88.16±0.3
DeiT	ImageNet	ViT-B	75.82±0.4	78.34±0.4	80.62±0.4	81.68±0.4	82.80±0.3	83.13±0.4	84.22±0.3	87.62±0.3
CE	ImageNet	ViT-B	76.78±0.4	78.81±0.4	80.65±0.4	81.13±0.3	82.69±0.3	82.77±0.3	85.60±0.3	88.48±0.3
DINO	ImageNet	ViT-B	76.44±0.4	79.11±0.4	81.23±0.4	82.01±0.4	84.16±0.3	84.44±0.3	86.25±0.3	88.04±0.3
CLIP	WebImageText	ViT-B	78.06±0.4	81.20±0.4	83.04±0.3	83.22±0.3	84.11±0.3	84.20±0.3	87.66±0.3	90.26±0.3

上的训练部分上进行训练，用所有的测试算法在 Meta-Dataset 上进行测试。此外，CLIP 模型在 4 亿文本-图像对数据集上进行了训练。

表2-1展示了训练算法集 $\mathcal{M}_{train}$ 与测试算法集 $\mathcal{M}_{adapt}$ 做笛卡尔积的算法组合 5-way 5-shot 结果表。可以看出， $\mathcal{M}_{train}$ 和 $\mathcal{M}_{adapt}$ 均为有序集，根据定义2.2，当固定住任意适应阶段算法时（表格中的一列），从上到下是单调递增的。相似地，当固定住任意训练阶段算法时（表格中的一行），从左到右是单调递增的。算法覆盖了相当具有代表性的小样本算法，以极大概率证明训练与适应算法是割裂的。不同的实验设定与数据使用见章末表2-3。

因为两阶段算法是割裂的，因此只需要用一个简单的贪心策略就可以就可以获得全局最优解。一个直接的理由就是，只要我们分别找到训练策略与测试策略的最优算法，它们的组合一定是最优的，例如，表2-1中 CLIP 与 Finetune 的组合分

别是训练和测试阶段最优的算法，同样也是最优的算法组合。

考虑到训练阶段算法不属于小样本学习范畴，并且来源广泛，在这里仅对实验中涉及到的测试阶段算法做出简单阐述。MetaOpt 测试头利用了线性分类器的两个性质：设计凸问题的最优性条件的隐式微分、最优问题的对偶公式，使得可以在适度增加计算开销情况下使用高维嵌入改进泛化，最终实现了一个可微的 SVM 分类器；NCC 测试头实际工程实现中是 ProtoNet 原型网络的测试头，该测试头计算每一个查询集样本与支持集类原型的距离进行分类；LR 分类器指的是逻辑斯蒂回归分类器，在多分类情况下也称为 Softmax 分类器，工程实现中等价于线性层；URL 测试头包含了一个线性映射层，将特征映射到同一表达空间中，从而进行分类；CC 测试头为余弦分类器，利用支持集与查询集样本的余弦距离分类；TSA 分类头通过在每一个测试域上学习一个部分微调的编码器网络，属于测试阶段算法，具体实现是 CNN 的卷积核上并联了适应参数实现的；eTT 是 TSA 在 ViT 架构上的相同版本；Finetune 指的是全参数微调，类似于 MAML 内循环阶段的过程。

2.3 两阶段独立分析

考虑到本章工作并非一人完成^①，本节的内容在贡献上不属于本文，但本节与下文又存在着紧密联系，因此在本节中只对两阶段的独立分析的结论作概要简述，省略一切细节过程。




图 2-1 类别数量递增小样本测试结果，对于训练数据中的每个类，都使用其全部样本。变量均对数化

1. 训练时，数据扩增相同量的情况下，增加类别数据要比更加每个类的样本数更有利。而且，在逐渐增加训练数据类别数时，小样本测试错误率和数据量呈现出缩放定律（Scaling Law^②），这意味着在起初增加类别数将带来更大的收益，可见在图2-2中，虽然每类的样本数并不多，但是类别数丰富，仅仅使用 5%-20% 的数据，就能获得不错的结果。这一点对于启发实际应用的小样本问题至关重要，随着训练数据中类别数的增加，监督学习模型的错误率下降符合缩放定律，而元

① 本章内容对应的发表论文属于两位共同第一作者，特此作出说明。

② 横纵坐标轴均对数化满足线性关系，因此原变量满足幂函数关系




图 2-2 逐类样本量递增小样本测试结果，一共使用 1000 类别分类数据，对于 ImageNet-val 的结果，并不计入平均结果当中。变量均对数化

学习方法 PN 始终弱于交叉熵损失训练，这与 Chen 等人 [45] 的发现是一致的。总结而言，对于下游为语义任务时，上游的训练第一要义应当尽可能丰富预训练数据的语义丰富度。




图 2-3 监督学习模型 ImageNet 性能与小样本性能对比，监督学习的 ImageNet 性能不是一个好的小样本性能指示器。参数均对数化




图 2-4 自监督学习模型 ImageNet 性能与小样本性能对比，自监督学习的 ImageNet 性能是一个好的小样本性能指示器。参数均对数化

2. 当前的机器学习社区有着越来越多的预训练模型，参考着多种多样的预训练方法，而这些视觉模型基本上都是在 ImageNet 上进行训练和测试的，以 ImageNet-val 上的探测性能作为衡量其优越性的指标，这是存在局限的。如图2-3和

图2-4所示，尽管相当多的监督学习模型在 ImageNet-val 上具备更高的准确率，但是它们在下游小样本任务上却产生了更高的错误率，说明他们在 ImageNet 上产生了过拟合；而自监督模型则是另一个结果，在 ImageNet-val 上表现更好的模型，也一定在下游跨域小样本任务上表现出更好的结果。这一点也比较容易理解，因为监督学习与自监督学习的学习目标不同，自监督学习不会过拟合在类别数据上，而监督学习模型则容易发生过拟合。




图 2-5 微调时，编码器与分类头的学习率分离能带来更好的效果

3. 如图2-5所示，模型微调时，考虑到分类头是随机初始化而编码器已被预训练完成，将骨架编码器的学习率与分类头的学习率分别设定，会产生更好的效果。这暗示着下游任务微调各网络部分的学习应当是异步的。

表 2-2 MiniImageNet 与 BSCD-FSL 基准数据集比较表

基准数据集	miniImageNet	Meta-Dataset									
		ILSVRC	Omniglot	Aircraft	Birds	Textures	QuickD	Fungi	Flower	Traffic Sign	COCO
平均类别数	5	29.5	28.8	10.1	17.9	5.9	27.9	27.6	11	24.9	21.1
平均样本数	1 或 5	18	4.8	35.7	19.1	47.9	21.4	15.9	29.1	22.9	23.7
平均支持集大小	5 或 25	374.5	88.5	337.6	316.0	287.3	425.2	361.9	292.5	421.2	416.1

4. 元学习范式到非元学习范式的转变实际上是在迎合数据集。在 Meta-Dataset 数据集出现之前，元学习方法占据主流，而非元学习方法在 Meta-Dataset 上的表现更好。本文认为是由于 MiniImageNet 的任务类别数、样本数与 Meta-Dataset 中的类别数、样本数的明显差异造成的，使得 Meta-Dataset 中的采样任务更适合于迁移学习。

2.4 本章小结

本章从社区中关于非元学习方法在小样本问题上的出色结果出发，重新思考元学习范式的统一形式的必要性，并利用大量实验证明了小样本的训练-测试两阶段算法时割裂的，因此启发社区可以分别单独对两阶段进行分析，找到在每个阶段上的最优算法，那么它们的组合也一定是最优的。基于此，本章对训练阶段和测试阶段在后文需要的结论进行了简要的总结归纳。

表 2-3 实验设定同表2-1，其中部分表格去除 MatchingNet 测试算法的原因
为在 1-shot 下其与 NCC 一致

Meta Dataset 测试 5-way 5-shot			测试算法						
训练算法	训练数据集	架构	MetaOpt	NCC	LR	URL	CC	TSA/eTT	Finetune
PN	miniImageNet	Conv-4	38.50±0.5	38.69±0.5	38.23±0.4	38.81±0.4	38.64±0.5	41.27±0.5	42.60±0.5
MAML	miniImageNet	Conv-4	42.92±0.5	43.00±0.5	42.65±0.5	42.51±0.5	42.97±0.5	44.55±0.5	46.13±0.5
CE	miniImageNet	Conv-4	44.49±0.5	44.88±0.5	44.88±0.5	44.48±0.5	44.82±0.5	46.20±0.5	46.92±0.5
MatchingNet	miniImageNet	ResNet-12	45.00±0.5	45.23±0.5	45.24±0.5	44.89±0.5	45.40±0.5	46.18±0.5	48.53±0.5
MAML	miniImageNet	ResNet-12	46.09±0.5	46.09±0.5	45.81±0.5	45.88±0.5	46.07±0.5	51.95±0.5	53.71±0.5
PN	miniImageNet	ResNet-12	47.32±0.5	47.53±0.5	47.33±0.5	47.53±0.5	47.65±0.5	49.36±0.5	53.06±0.5
MetaOpt	miniImageNet	ResNet-12	49.16±0.5	49.52±0.5	49.53±0.5	49.42±0.5	49.73±0.5	52.01±0.5	53.90±0.5
CE	miniImageNet	ResNet-12	51.09±0.5	51.42±0.5	51.60±0.5	50.94±0.5	51.71±0.5	53.81±0.5	54.68±0.5
Meta-Baseline	miniImageNet	ResNet-12	51.24±0.5	51.56±0.5	51.67±0.5	51.23±0.5	51.77±0.5	53.87±0.5	54.54±0.5
COS	miniImageNet	ResNet-12	51.23±0.5	51.53±0.5	51.31±0.5	51.87±0.5	51.72±0.5	54.18±0.5	54.98±0.5
PN	ImageNet	ResNet-50	52.50±0.5	52.84±0.5	52.71±0.5	52.90±0.5	52.93±0.5	54.34±0.5	57.40±0.5
IER	miniImageNet	ResNet-12	53.31±0.5	53.63±0.5	53.82±0.5	53.24±0.5	53.98±0.5	56.32±0.5	56.98±0.5
Moco v2	ImageNet	ResNet-50	54.89±0.5	55.38±0.5	55.64±0.5	55.77±0.5	55.70±0.5	58.13±0.5	59.99±0.5
DINO	ImageNet	ResNet-50	60.81±0.5	61.37±0.5	61.61±0.5	61.96±0.5	61.81±0.5	62.69±0.5	63.61±0.5
CE	ImageNet	ResNet-50	62.34±0.5	62.88±0.5	62.90±0.5	63.55±0.5	63.18±0.5	65.04±0.5	65.87±0.5
BiT-S	ImageNet	ResNet-50	62.41±0.5	62.95±0.5	63.15±0.5	63.40±0.5	63.40±0.5	65.02±0.5	67.05±0.5
CE	ImageNet	Swin-B	64.03±0.5	64.46±0.5	64.38±0.5	65.22±0.5	65.01±0.5	-	69.12±0.5
DeiT	ImageNet	ViT-B	64.20±0.5	64.62±0.5	64.43±0.5	65.31±0.5	65.11±0.5	66.25±0.5	69.12±0.5
DINO	ImageNet	ViT-B	64.86±0.5	65.36±0.5	65.31±0.5	66.05±0.5	65.91±0.5	67.26±0.5	67.89±0.5
CE	ImageNet	ViT-B	67.19±0.5	67.61±0.5	67.56±0.5	68.00±0.5	67.85±0.5	69.78±0.5	72.14±0.4
CLIP	WebImageText	ViT-B	67.95±0.5	68.68±0.5	69.10±0.5	69.85±0.5	68.85±0.5	70.42±0.5	74.96±0.5
MiniImageNet 测试 5-way 5-shot			测试算法						
训练算法	架构	MatchingNet	MetaOpt	NCC	LR	URL	CC	TSA/eTT	Finetune
MAML	Conv-4	59.80±0.3	57.99±0.4	58.86±0.2	60.93±0.3	60.81±0.4	61.83±0.3	62.40±0.3	62.03±0.5
PN	Conv-4	63.71±0.5	64.12±0.5	63.67±0.5	65.78±0.5	65.78±0.4	65.82±0.5	65.69±0.4	66.35±0.5
CE	Conv-4	64.09±0.4	66.41±0.4	67.93±0.3	68.92±0.5	68.63±0.4	69.08±0.5	69.22±0.4	69.51±0.6
MatchingNet	ResNet-12	69.48±0.3	69.71±0.3	69.75±0.6	70.92±0.4	70.86±0.4	71.00±0.4	71.15±0.2	72.31±0.4
MAML	ResNet-12	70.27±0.3	68.37±0.6	70.09±0.4	71.94±0.4	71.33±0.3	72.10±0.5	75.70±0.5	76.18±0.3
PN	ResNet-12	73.64±0.4	74.03±0.4	74.99±0.5	75.46±0.4	75.72±0.4	75.65±0.4	76.99±0.3	79.62±0.2
MetaOpt	ResNet-12	75.21±0.4	76.51±0.5	77.69±0.4	78.09±0.5	78.36±0.4	78.43±0.4	80.55±0.2	81.44±0.2
CE	ResNet-12	76.66±0.4	77.66±0.4	79.97±0.4	80.01±0.5	80.11±0.5	80.34±0.5	80.65±0.1	80.84±0.2
Meta-Baseline	ResNet-12	77.06±0.4	77.59±0.4	79.85±0.2	80.54±0.5	80.52±0.4	80.77±0.4	80.97±0.3	81.42±0.2
COS	ResNet-12	79.70±0.3	80.07±0.4	81.01±0.3	81.28±0.4	81.54±0.4	81.52±0.5	81.97±0.2	83.26±0.2
IER	ResNet-12	80.37±0.3	81.33±0.3	82.80±0.3	83.71±0.3	83.83±0.3	84.04±0.3	83.53±0.3	84.02±0.2
MiniImageNet 测试 5-way 1-shot			测试算法						
训练算法	架构	MetaOpt	NCC	LR	URL	CC	TSA/eTT	Finetune	
MAML	Conv-4	45.97±0.4	46.24±0.5	47.62±0.5	46.81±0.6	47.40±0.5	47.55±0.4	47.40±0.3	
PN	Conv-4	49.79±0.4	50.95±0.4	50.89±0.4	51.01±0.5	50.95±0.4	50.97±0.3	50.65±0.4	
CE	Conv-4	51.28±0.5	51.68±0.7	51.07±0.6	52.18±0.6	51.86±0.7	52.88±0.3	51.87±0.4	
MatchingNet	ResNet-12	54.52±0.5	54.96±0.5	54.85±0.5	54.84±0.6	54.89±0.5	55.27±0.4	55.52±0.4	
MAML	ResNet-12	56.43±0.4	55.80±0.7	57.14±0.7	56.06±0.8	57.03±0.7	57.86±0.4	58.49±0.2	
PN	ResNet-12	59.91±0.4	60.25±0.7	60.26±0.7	60.01±0.6	60.26±0.7	60.37±0.5	60.67±0.2	
MetaOpt	ResNet-12	60.40±0.3	60.82±0.5	60.40±0.5	61.79±0.5	60.91±0.5	61.89±0.4	62.58±0.4	
CE	ResNet-12	62.53±0.6	62.88±0.6	62.55±0.6	63.15±0.6	62.94±0.6	63.46±0.4	63.33±0.4	
Meta-Baseline	ResNet-12	63.99±0.2	64.92±0.7	64.84±0.7	64.55±0.7	64.91±0.7	64.92±0.3	64.97±0.2	
COS	ResNet-12	64.06±0.3	64.73±0.9	64.71±0.9	64.60±0.8	64.70±0.9	64.92±0.4	65.01±0.4	
IER	ResNet-12	65.05±0.1	66.45±0.6	66.17±0.6	66.68±0.6	66.48±0.6	66.25±0.3	65.86±0.4	

第三章 高效实现小样本迁移学习

在第二章中的分析可以得到，训练阶段的算法对测试阶段的算法是透明的，二者之间不存在互感关系。一个很简单的监督学习预训练网络配合线性分类器就可以获得好的表现，同时如果在测试阶段使用模型微调手段，则会获得接近于最先进的性能，在本章中将通过一个案例研究再一次说明这个问题。另外，在第二章的模型微调研究中，本文发现模型微调技术面临着两个直接问题，一是超参数的搜索非常困难，由于合适的超参数范围窄，导致不得不花费超过 80% 的时间消耗在学习率、迭代数的超参数搜索上，并且由超参数分布观察到支持集和查询集的域差异问题，这是小样本学习的底层问题，这要求在高效微调的同时，还要尽可能达到泛化；另一个问题是使用全参数微调技术时间和显存消耗仍然难以承受，即便是确定好超参数，也要付出成倍于非微调类测试方法的时间。超参数和高效微调算法分别对应3.2和3.3。

3.1 非线性度量增强特征比较

在第二章中可以获得一个简单的结论，训练阶段的模型越强越好。本节中，不仅将再一次说明这个结论，而且还将讨论社区过去的一个杰出工作 DeepBDC^[76]。正如1.2中阐述，小样本学习在测试阶段的任务数据域甚至任务类型都是未知的，这势必会带来一个问题：预训练知识与测试任务知识之间的偏差。这个偏差并不是什么问题，这是自然存在的，小样本任务的支持集正是用来去纠正这个偏差的。但是预训练模型在面对知识偏差时，存在了一些有趣的现象。本文在试图解释这些现象的过程中，一方面再次强调了第二章中的结论，另一方面也对 DeepBDC[®]这个工作有了进一步的认识。

预训练编码器对域外样本编码存在过度自信。Luo 等人^[20]的工作揭示出，当支持集中的样本较少时，编码器模型将很难获取到足够的知识来编码查询集中来自真实分布中的图像，因此会造成编码器的特征向量在某些通道维度上估计不准，这种通道估计的偏差会造成图像相似度比较的崩溃。试想，如果两个特征向量虽然来自同一类样本，但是由于通道的估计偏差，导致同一个通道对两个相同类样本的估计相差过大，在后续的度量比较中，将会拉远这两个样本之间的距离。而同一个通道所代表的属性是固定的，不会因不同的输入样本而异，来自同类的两个样本在类相关通道上的表达应当相似，但通道偏差对这一点造成了消极影响。

① CVPR 2022 Oral Presentation

同时该工作还指出，类间通道特征均值差别大而类内通道特征方差差别小的通道更应该被重视。这也反映出一个问题，即部分特征通道的估计方差变大导致特征估计易偏移。如果某一个通道的估计方差过大，不管该通道是否是类相关的通道，都会造成较大的影响：如果是类相关通道，方差过大会造成同类样本的类相关通道产生较大偏差；如果是类不相关通道，方差过大也会造成样本间度量比较的异常结果。在 Luo 等人的实验中，仅需 3-5 个通道的特征，即可完成对 2-way 5-shot 任务的分类，说明了特征在通道维度上存在大量的冗余，为了增强特征的稳定性，削弱模型过度自信的通道表达，增强模型不自信的通道表达，Luo 等人设计了一个基于外部数据的特征纠偏算法，非常一致且有效的缓解了模型的特征通道偏差影响。但需要说明的是，该算法需要统计外部同语义数据的特征通道均值与方差，这在实际工程中不可能实现。

能不能不借助外部数据缓解预训练模型的特征估计偏差问题呢？本文注意到了发表于计算机视觉国际会议 CVPR 2022 的杰出工作 DeepBDC，尽管该工作并不是为了解决上述问题，但本文在对其分析的过程中，发现了二者的联系。Xie 等人^[76]的工作中发现深度布朗距离协方差可以有效的帮助小样本学习在元学习范式下取得最佳的性能，他们将其解释为深度布朗距离协方差是一种联合分布度量，与之前元学习度量方法中常用的余弦距离、欧氏距离等都有所区别，而联合分布度量在小样本问题中更有效，但他们并未对此给出更深的见解。本文将从以 Xie 等人工作为核心的一个铺垫实验入手，逐步引出用于度量比较的新距离指标，并最终证明这种度量指标在原型网络分类头下就是样本距离相关系数（一种非线性关系度量）。

铺垫实验：深度布朗距离协方差直接应用于原型网络测试算法。

原型网络分类头在分类时，需要将特征提前归一化到超球面上，以便在后续计算时直接使用向量点乘直接计算特征之间的余弦值，也就是余弦相似度。如果这是对测试算法简单改动一下，分类器设计仍然沿用原型网络，但是样本与类原型的特征去计算布朗距离协方差，则可以观察到非常有趣的结果：在没有任何参数学习的情况下，使用在 MiniImageNet 上训练的 Conv-4 和 ResNet12 模型，竟然可以在 Meta Dataset 上的多个数据集上得到明显的结果提升，本文将这种测试度量命名为 DIS-R，如3-1所示。

这个实验结果非常有趣，仅仅只是把样本与类原型的布朗距离协方差求余弦值，而不是直接对特征求余弦值，就可以取得平均 6 个百分点的增益，这背后的原因是什么？本文首先从布朗距离协方差入手分析。通常衡量随机变量关系都基于线性相关关系，如皮尔森相关系数、斯皮尔曼秩相关系数等，前者是应用最为

表 3-1 距离相关系数度量比较分类结果，使用 PN 以类均值比较的分类头设置，Cosine 表示余弦相似度，DIS-R 指样本距离相关系数作为度量比较，模型为 MiniImageNet 上经过交叉熵训练的 Conv-4 与 ResNet-12

	Omniglot	Aircraft	CUB	DTD	QuickD	VGG	Traffic	MSCOCO	Avg
Cosine	85.10	37.03	50.40	55.17	60.13	76.57	45.93	57.10	58.43
DIS-R	90.17	51.03	59.40	49.27	67.77	80.47	60.53	53.23	63.98
Cosine	87.33	40.86	60.06	67.33	68.30	85.20	58.70	64.73	66.56
DIS-R	94.50	56.90	65.70	65.80	73.00	89.83	68.16	64.40	72.29

广泛的线性关系度量，而后者可以度量单调性。但它们都只能衡量变量之间的线性相关关系，对于非线性关系则无法衡量，这可以通过图3-1直观地观察到。




图 3-1 线性相关度量示意图，左 2 图表示皮尔森相关系数与斯皮尔曼秩相关系数可以很好的表示线性相关关系，右 2 图表示其无法衡量非线性关系，PC 表示皮尔森相关系数，SC 表示斯皮尔曼秩相关系数。图引自 CowLey^[77]

关于非线性关系，随机过程中随机变量概率分布的特征函数有一个很好的性质，即如果随机变量 X 和 Y 是相互独立的，有且仅有 $\mathcal{F}(XY) = \mathcal{F}(X)\mathcal{F}(Y)$ ，其中 $\mathcal{F}(X)$ 、 $\mathcal{F}(Y)$ 分别是随机变量 X 、 Y 的边缘特征函数。由于特征函数反映了随机变量的分布性质，因此可以用来衡量任何关系。随机变量 X 和 Y 的边缘分布与二者联合分布的特征函数差的积分，则可以用来衡量这种分布之间的距离。本文沿用 Feuerverger 等人^[78]提出的特征函数距离 T ，有：

$$T = \iint [\mathcal{F}(s, t) - \mathcal{F}(s)\mathcal{F}(t)]^2 w(s, t) ds dt$$

而 Xie 等人^[76]的工作中则使用了该度量的离散版本距离协方差，作为损失函数参与模型训练。本研究在实验中发现，如果直接将距离协方差用于推理阶段，则会产生很好的效果，而且在分布外数据上提升明显，本文将分析这背后产生的原因。

定义 3.1 对于随机变量距离 $\mathbf{X} \in R^p$ 和 $\mathbf{Y} \in R^q$ ，每个随机变量各采样 n 个样本。

定义变量之间的距离协方差为：

$$\mathcal{V}_n^2(\mathbf{X}, \mathbf{Y}) = \|\mathcal{F}_{\mathbf{XY}}^n(t, s) - \mathcal{F}_{\mathbf{X}}^n(t)\mathcal{F}_{\mathbf{Y}}^n(s)\|^2 \quad (3-1)$$

式3-1可进一步写成：

$$\begin{aligned} \mathcal{V}_n^2(\mathbf{X}, \mathbf{Y}) = & \frac{1}{n^2} \sum_{k,l=1}^n |\mathbf{X}_k - \mathbf{X}_l|_p |\mathbf{Y}_k - \mathbf{Y}_l|_q + \frac{1}{n^2} \sum_{k,l=1}^n |\mathbf{X}_k - \mathbf{X}_l|_p \frac{1}{n^2} \sum_{k,l=1}^n |\mathbf{Y}_k - \mathbf{Y}_l|_q \\ & - 2 \frac{1}{n^3} \sum_{k=1}^n \sum_{l=1}^n |\mathbf{X}_k - \mathbf{X}_l|_p |\mathbf{Y}_k - \mathbf{Y}_l|_q \end{aligned} \quad (3-2)$$

因此，距离协方差的一般公式表达为：

$$\begin{aligned} \mathcal{V}^2(\mathbf{X}, \mathbf{Y}) = & E[|\mathbf{X} - \mathbf{X}'| |\mathbf{Y} - \mathbf{Y}'|] + E[|\mathbf{X} - \mathbf{X}'| [E[|\mathbf{Y} - \mathbf{Y}'|] \\ & - E[|\mathbf{X} - \mathbf{X}'| |\mathbf{Y} - \mathbf{Y}''|] - E[|\mathbf{X} - \mathbf{X}''| |\mathbf{Y} - \mathbf{Y}'|] \end{aligned} \quad (3-3)$$

定义 3.2 根据相关系数与协方差的关系，得出距离相关系数的定义。

$$\mathcal{R}(\mathbf{X}, \mathbf{Y}) = \frac{\mathcal{V}(\mathbf{X}, \mathbf{Y})}{\sqrt{\mathcal{V}(\mathbf{X})} \sqrt{\mathcal{V}(\mathbf{Y})}} \quad (3-4)$$

原型网络分类头在分类时，需要将特征提前归一化到超球面上，以便在后续计算时直接使用向量点乘直接计算特征之间的余弦值，也就是余弦相似度。当对特征计算布朗距离协方差时，等同于计算 $\mathcal{V}^2(\mathbf{X})$ ，而在之后计算协方差 $\mathcal{V}^2(\mathbf{X})$ 和 $\mathcal{V}^2(\mathbf{Y})$ 的余弦距离时，通过 L2 归一化和点乘恰好计算得到了距离相关系数，即

$$\frac{\mathcal{V}^2(\mathbf{X})}{\|\mathcal{V}^2(\mathbf{X})\|} \cdot \frac{\mathcal{V}^2(\mathbf{Y})}{\|\mathcal{V}^2(\mathbf{Y})\|} = \frac{(\mathcal{V}^2(\mathbf{X}, \mathbf{Y}))^2}{\mathcal{V}^2(\mathbf{X}) \cdot \mathcal{V}^2(\mathbf{Y})} = \mathcal{R}^4(\mathbf{X}, \mathbf{Y}) \quad (3-5)$$

这也就是说，将距离协方差在进行 PN 类均值比较计算时，实际上是得出的是每一个查询集样本特征与支持集中类别均值特征的距离相关系数（的四次方），而这种距离相关系数是非线性度量。那为什么非线性距离度量有效呢？因为预训练编码器与测试任务之间存在知识偏差，而编码器的作用正是编码非线性，正如核函数之于 SVM 的作用类似，这种情况下只需要线性分类器足矣。而当编码器和下游知识存在偏差时，编码器不能有效的将下游数据编码进特征空间的线性子空间内，因此在分类阶段对特征求非线性度量恰好在一定程度上弥补了这一点：即便特征空间不完全线性可分，但度量指标可以容忍和衡量一定的非线性，因而性能得以提升。而在 Xie 等人的工作中，并未提到这一点，本文认为 DeepBDC 在某种角度来看，也正是因为这一点，得到了不错的性能，而不仅仅是联合分布的因素。

依照上述分析，如果当编码器的预训练知识足够强的时候，是否意味着 DIS-R

的增益会变弱呢？本文进一步地在 ImageNet 上训练的 ResNet18 和 ResNet34 进行了实验，结果见表3-2。可以发现，当预训练模型足够强之后，它所编码的域外样本在特征空间中也相对线性可分，因此非线性度量带来的增益就会减少很多。

表 3-2 实验设置与表3-1一致，区别为模型是在 ImageNet 上经过交叉熵训练的 ResNet18 和 ResNet34

	Omniglot	Aircraft	CUB	DTD	QuickD	VGG	Traffic	MSCOCO	Avg
Cosine	90.97	50.43	71.73	70.00	73.23	87.53	73.93	75.70	74.19
DIS-R	93.17	52.70	70.53	69.43	76.43	87.80	75.83	73.30	74.90
Cosine	88.20	53.63	74.73	71.57	72.60	85.87	74.10	77.47	74.77
DIS-R	91.40	54.83	74.53	70.33	74.13	84.60	76.67	74.83	75.16

以上实验说明，预训练模型和下游测试数据之间存在分布偏差，而这种分布偏差又无法通过支持集中的知识纠正，这个研究案例支持了分布偏差的假设。实际上，当预训练模型更强大时（在更多更多样的数据集上预训练），DIS-R 所能取得的性能增长会越来越小，这同样暗示着分布偏差在缩小，再一次印证了第二章中训练阶段的分析结论，即训练模型越强大越好，越强大的预训练模型拥有的知识越丰富，在下游任务的表现越好。但同时实验也发现，DIS-R 并非在所有数据集上都有良好的表现，如 DTD、MSCOCO、ImageNet，这可能与模型训练分布的偏差很小有关，因为 DIS-R 虽然能够度量非线性关系，但也更容易受到噪声的影响。模型在不微调的情况下的分布偏差问题，叠加小样本学习可供调整的数据更少的窘境，则意味着在微调时更容易出现过拟合和噪声影响，这可能需要设计更加精细的微调算法如部分微调等缓解。

3.2 超参数的随机性策略集成

在第二章中，所有训练阶段模型的微调测试方法结果，其超参数都是通过与测试数据域相同的验证数据上搜索而来。然而，但真正的小样本学习中，验证集的存在本就是不合理的，模型既然都无法知晓推理阶段会遇到什么数据域上的任务，更不可能提前拥有与推理阶段数据域相同域的验证数据。本文抛开这种仅存在于学术论文社区中的不合理的验证数据存在假设，期望直接从推理阶段中的测试任务支持集上寻找超参数。但很容易知道，超参数在一般的学习过程中，都是比较敏感的，例如 Jascha 等人发现在元学习中的超参数关于元损失的分布中存在分形^[79]，这意味着哪怕是最优的范围内，其子范围内的超参数也可能导致学习无法收敛。首先，本文需要验证学习率敏感的事实并且给出一个假设：学习率之所

以敏感，是因为支持集上的超参数搜索空间比查询集上的超参数搜索空间要大很多，因此在查询集上表现良好的学习率范围自然是收窄的。

如图3-2所示，在相同的超参数搜索空间中，显然网络对于支持集上的超参数敏感性要远低于查询集的超参数敏感性，多数搜索空间实际上都还不错，这是因为支持集的样本数极少，而编码器网络已经学习到足够好的知识了，因此对于网络来说，支持集的分类学习是一个极其简单的任务，因此网络可以调整参数的范围大一些，也都可以支持集上表现得很好，所以对于超参数的敏感性就没有那么强。但是反观查询集则完全不同，查询集实际代表的是现实中的真实分布，这是一个终极任务，任何机器学习目标都要试图泛化的任务，在查询集的超参数搜索空间的实验中，虽然只取了 75 个样本组成查询集，但是已经表现出了超参数敏感性：并不是很多超参数在支持集上微调之后都能在真实分布子集的查询集上表现好，这一方面是因为本身查询集所代表的真实分布是一个很困难的任务，本就没有那么多超参数可以优化到全局最优解；另一方面是因为支持集的知识极少，很可能就不存在一个超参数组合，能够借助支持集优化到全局最优解。




图 3-2 小样本任务支持集与查询集上学习率搜索对比，左图为支持集搜索结果，右图为查询集搜索结果，搜索空间为 $1e-6$ 到 $1e+1$ 的对数等比空间，使用学习率分离设定，分别使用网格搜索编码器学习率和分类头学习率，Epoch 设为 5，显示色彩中间值为 0.6，模型为交叉熵损失训练的 ResNet12

如图3-3所示，首先可以得出在整个微调过程中，编码器对于学习率的敏感度要更大一些，不管是在支持集上还是在查询集上，合适的学习率区间对于编码器来说都是更窄的，而分类头的学习率则不太敏感，这也说明了 [45] 等人使用余弦分类器/逻辑斯蒂回归就能取得不错结果的另一个原因：分类头只需要优化到合适即可，并不需要特别的优化，因此诸如逻辑斯蒂回归等有优化迭代次数限制的算法

也可以取得不错的结果。另外一个观察是，对于在支持集上的超参数搜索，编码器学习率合适区间相较于查询集要宽泛许多，如图中红线所示，支持集适合区间占比超过 55%，而查询集只有 40%，这同样也验证了图3-2的结果，查询集和支持集的适应学习率差异很大。




图 3-3 小样本任务支持集与查询集上学习率关联对比，上图为支持集结果，下图为查询集结果。搜索空间为 $1e-6$ 到 $1e+1$ 的对数等比空间，分别使用网格搜索编码器学习率和分类头学习率，Epoch 设为 5。中间变量为编码器学习率，右侧变量为分类头学习率，左侧数值为准确率

因此本文需要讨论出现差异的原因，上文从优化角度讨论的观点，认为支持集出现差异的原因：支持集数据很少，支持集分布和查询集代表的真实分布差得远，这暗示着小样本学习中分布偏差问题，而这种分布偏差问题导致了很多问题。

如何缓解超参数搜索消耗巨大和支持集、查询集分布差异的问题呢？实验中发现，在某一个任务上微调后性能相对于学习率的分布，是非常破碎的，虽然呈现出了一定的宏观规律，但是在一个确定的范围内，分布是非常曲折的，可以理解为在一个坑坑洼洼的函数表面做优化，因此超参数优化去寻找最优超参数这条路通过超参数梯度是不可行的。所以，对于超参数搜索消耗大的问题，本文可以

采用一些启发式方法 (如 Tree-Structured Parzen Estimator [80,81]) 等减少超参数的搜索范围, 从而减少总体的搜索消耗。但又如何解决分布差异问题呢? 试想这样一个问题, 虽然支持集并不能覆盖真实分布, 甚至不能匹配真实分布子集的查询集, 但是支持集给出了一个大致的范围, 也就是说, 支持集的分布一定是在真实分布当中的, 向支持集的优化在优化初期是朝着真实分布的方向的, 但随着优化的进行, 随即就陷入了过拟合状态。这是一个边际效应递减的过程, 只有适度的优化才能带来更大的收益, 过度的优化反而会带来适得其反的效果。但是机器学习并不能控制优化的过程, 它以降低训练集误差为优化目标, 认为这等同于降低泛化误差, 这在小样本学习上是很难成立的。因此, 如何进一步挖掘在支持集上优化的过程产生的收益是值得的。毕竟, 在支持集上的每一步优化, 可能并不一定在支持集上带来先进的性能, 但正如上文分析, 支持集分布作为真实分布的子集, 优化方向大概率是没错的, 那么支持集上并不先进的某一步优化, 可能就会在真实分布的另一部分未知子集上带来好处, 也有可能给查询集的某部分数据带来好处, 这与 Zhu 等人 [82] 的关于数据多视图观点相似。

沿着这个思路, 一个自然而然的想法可以产生: 集成学习。如果将支持集上每一步的优化过程对应的模型参数在查询集上的输出集成起来, 任一优化过程步骤对应的中间模型都可能在查询集上的某一部分数据表现较好, 集成之后就有可能在整体查询集上的平均性能得到增益。另外, 这种做法还带来了一个好处, 不需要再准备验证数据集并在验证数据集的任务上寻找超参数了, 而是直接在测试数据集/真实分布上的任务直接测试, 这将大大的减少算法准备的时间^①。从另外一个角度考虑, 由于对每一个查询集样本的预测都是许多个相同类型算法的集成, 不同的算法实体之间存在着基于梯度优化的关联, 这相当于一组方差较大的估计, 根据机器学习的偏差-方差权衡, 这可能意味着同一个查询集样本所有预测的均值的偏差较小, 这可能也是集成学习有效的原因之一。

那么现在需要考虑的问题是如何获得一组超参数? 本文选择对验证集的任务搜索超参数的方法进行了实验, 如表3-3第 1、2 行所示。在验证集上寻找合适的超参数并在测试集上应用时社区内的普遍做法, 可以看到在验证集上搜索超参数是有效的。其中, 基于 TPE 的启发式搜索的最优超参数应用到测试任务上时, 往往可以产生比网格搜索更好的效果, 这是因为 TPE 的搜索方向会随着搜索的进行逐渐收敛到最优解区域附近, 因此会在搜索后期产生更好的超参数组合。但需要思考的是, 真正的小样本任务是来自于未知分布的, 存在验证数据集的假设本不存在, 只是为了实验方便而设计的, 如何面对更实际的小样本任务微调时的超参数

① 可能需要借助验证数据找出一个合适的超参数搜索范围

选择问题呢？一个直接的选择是直接在测试任务上做搜索，如在测试任务的支持集上执行交叉验证搜索，确定合理的超参数，但是支持集本就很少的样本还要拿出一部分作为验证数据，这显然会造成搜索上的困难，并且这种方案的开销也是不可小觑的。

表 3-3 超参数集成学习实验结果，模型使用 ResNet12，优化器为 Adam，超参数为编码器和分类头学习率。第 1、2 行为在验证数据集上搜索最优超参数，第 3、4 行为直接在测试任务上进行集成学习。实验在 Meta-Dataset 的 6 个数据集上进行，分别从验证部分和测试部分采样了 40 个任务

	Aircraft	CUB	DTD	QuickD	VGG	MSCOCO	Avg
网格搜索（验证）	52.96	59.13	65.13	76.30	86.27	63.27	67.18
TPE 搜索（验证）	53.70	60.37	66.80	78.53	88.50	63.99	68.65
暴力集成（测试）	55.60	63.07	64.93	79.47	91.33	65.86	70.04
策略集成（测试）	55.60	63.33	65.07	80.13	91.80	66.20	70.36

从上文的分析可以知道，集成不同超参数的模型输出可能是一个更好的选择。因此本文首先设计了一个暴力集成的探索实验，即确定好超参数搜索空间之后，将每一组超参数的模型微调结果都不分好坏的集成起来，集成方式为逻辑值输出平均，之后重新进行归一化，得到最终的预测分布。实验中设定的超参数搜索空间为 $\{1e-6, 1e-5, 1e-4, 1e-3, 1e-2, 1e-1, 1e0\} \otimes \{1, 3, 5, 7, 9\}$ ，支持集迭代次数固定为 5。可以从表3-3中第 3 行看到，这种直接在测试任务上的集成可以表现出不错的效果，产生了比在验证集上搜索最优超参数更好的性能，证明了这种随机性集成的有效性。

这种有效性的原因除了可能是因为上文中分析的不同的微调版本模型可能有利于分类真实分布中的部分子集样本之外，还可能与随机集成操作本身的性质有关 [82]。虽然目前仍没有足够的理论支持，但是在实验中发现，如果一个表现不佳的特征与一个表现出色的特征集成，那么集成后的特征将仍能保持靠近出色特征的性能，也就是说，一个好的特征和一个坏的特征的集成，会更靠近好的特征，而坏的特征并不会产生过度的干扰。这一点在 Wang 等人 [83] 中也有相似的观点，他们证明了集成后的特征不会低于特征的平均性能。回归超参数的实验中，如果一个好的超参数组合与一个不好的超参数组合各自微调得到的网络输出的预测结果相集成，那么最终的结果更有可能会靠近原本那个好的超参数组合微调得到的模型的结果，而不好的超参数组合微调得到的模型预测则会被忽略。这可能是超参数集成有效的另一个可能原因，但仍需要进一步研究。

如果沿着这个思路继续思考，暴力集成所有的超参数意味着存在一些表现很差的微调后模型的预测也被集成进去，从图3-2中的对比可以发现，多数情况下，在查询集上表现较好的超参数组合在支持集上同样也表现好，这是很显然的。因为支持集只是极小的一部分真实分布的子集，能够使支持集准确率达到好的水平的超参数组合很多，但是这些组合中大概率会包含准确率能覆盖更全面的真实分布的超参数组合。对于选定的超参数范围，实际上可以对部分超参数组合应用一个预先检验，这是很直观的：如果一组超参数在支持集上都表现很差，那么它在微调完成之后再查询集上的结果大概率也会很差。因此，本文设计一个简单的策略，命名为策略随机集成，即如果存在一组超参数，都不能在支持集上微调获得很好的支持集性能，那就不应该参与查询集的预测结果集成。相关结果见表3-3第4行，发现策略随机集成多数情况下都能产生比暴力集成更好的结果。

表 3-4 微调时学习率与模型和数据的关系，每一行对应一个编码器模型在 8 个数据集上最优超参数，其中异常学习率用加粗表示

架构	训练方法	Omniglot	Aircraft	CUB	DTD	QuickD	VGG	Traffic	MSCOCO
Conv4	ProtoNet	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-04
Conv4	MAML	1.00E-02	1.00E-02	1.00E-03	1.00E-03	1.00E-02	1.00E-02	1.00E-03	1.00E-03
Conv4	CE	1.00E-03	1.00E-03	1.00E-03	1.00E-05	1.00E-03	1.00E-03	1.00E-03	1.00E-04
ResNet12	MatchingNet	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04
ResNet12	ProtoNet	1.00E-04	1.00E-04	1.00E-05	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04
ResNet12	MAML	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03	1.00E-03
ResNet12	CE	1.00E-04	1.00E-04	1.00E-04	1.00E-05	1.00E-04	1.00E-04	1.00E-04	1.00E-05
ResNet12	MetaOpt	1.00E-04	1.00E-04	1.00E-04	1.00E-05	1.00E-05	1.00E-04	1.00E-04	1.00E-05
ResNet12	MetaBaseline	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-05
ResNet12	COS	1.00E-04	1.00E-04	1.00E-06	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04
ResNet12	IER	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-03	1.00E-04
ResNet50	ProtoNet	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04	1.00E-04
ResNet50	CE	1.00E-03	1.00E-03	1.00E-08	1.00E-04	1.00E-03	1.00E-03	1.00E-03	1.00E-04
ResNet50	BiT-S	1.00E-04	1.00E-04	1.00E-04	1.00E-05	1.00E-04	1.00E-04	1.00E-04	1.00E-05
ResNet50	BiT-M	1.00E-04	1.00E-04	1.00E-05	1.00E-06	1.00E-04	1.00E-05	1.00E-04	1.00E-04
ResNet50	MoCo-v2	1.00E-05	1.00E-05	1.00E-05	1.00E-08	1.00E-05	1.00E-06	1.00E-05	1.00E-05
ResNet50	DINO	1.00E-03	1.00E-04	1.00E-04	1.00E-05	1.00E-03	1.00E-05	1.00E-03	1.00E-04
ViT-B	DINO	1.00E-05	1.00E-04	1.00E-05	1.00E-05	1.00E-04	1.00E-05	1.00E-04	1.00E-05
ViT-B	CLIP	1.00E-05	1.00E-05	1.00E-05	1.00E-05	1.00E-05	1.00E-05	1.00E-05	1.00E-05

从另一个角度来看策略随机集成，由图3-3可以看到，其实预定义的超参数搜索空间中，对于编码器骨架的超参数空间，有接近一半的搜索空间都是过大的，这些不合理的超参数会使得模型在极小样本上微调之后产生意想不到的结果，比如优化崩溃。因此，这种超参数异常大概率多数都是由于超参数过大引起的优化崩溃导致，这些导致优化崩溃的超参数微调的模型，其编码的特征空间自然也是不好的，集成这些特征空间的编码将不会带来任何收益。实际上，策略集成的动机很平凡，并不是什么精妙的算法设计，本节最核心的内容是集成学习可以在小样

本学习中展现出很不错的效果，这一点非常重要，相似的思想在其它工作中^[84]也有体现。

最后一个问题是，如何确定预先设定好的超参数集成范围呢？从表3-4中的实验统计数据中可以发现，针对超参数更敏感的编码器模型，对于一个固定的模型（某一种架构和训练方法的组合），其在大部分数据集上的最优超参数是一致的，不会超过1个数量级的改变，而异常学习率可能与下游数据集本身的特点有关。这也就意味着，如果想要为某一个编码器模型找到一个合适的超参数范围，只需要在已有的几个数据集上探测出合适的超参数范围，就可以泛化到下游多数数据集中。这是一个很好的性质，但其中的原理仍不清楚，留待未来进一步研究。

3.3 参数高效的模型微调算法

上一节讨论了模型在微调的情况下，在小样本学习上出现的问题以及解释，核心在于由于问题本身的限制，支持集数据很大概率不能表达类语义，所以支持集和查询集之间其实存在着很大的知识偏差。进一步思考，在模型微调的情况下，知识偏差会对模型微调产生什么影响呢？试想，既然支持集中的知识极为有限，换一个角度，在支持集上进行微调就更容易被噪声影响，并且无法靠更多的数据获得的知识在学习过程中摒弃噪声。这对显式的学习过程提供了一个好的角度，如何在学习过程中增加先验知识从源头上压制噪声呢？

3.3.1 频率先验增强的高效模型微调

神经网络有一个天然偏置是简约性（Simplicity），即神经网络天然倾向于学习最简单的知识和模式，然后再学习困难的模式。这种简约性的其中一个原则就是频率原则^[85]，即神经网络在拟合数据的过程中经常会先学习低频，而后慢慢学习高频。自然界中大部分信号都有一个特征，强度随频率增加而衰减。函数在频率空间也都有衰减的特征，函数越光滑，衰减越快，诸如常见的 ReLU 激活函数^[86]在频率空间也是二次方衰减。在梯度下降的计算中，可以证明低频信号对梯度的贡献要大于高频。回到小样本任务中，支持集中的噪声往往是以高频的成分出现的，而分类知识通常隐含在低频成分当中^[85]，考虑到编码器模型已经完成了预训练，在新的一个小样本任务支持集上并不需要学习很多高频特征，因此只学习低频知识是一个保证鲁棒性和抑制噪声学习的合理选择。

抑制噪声有两个选择，一个是从数据上入手，直接利用傅里叶变换在频域学习相应的掩码^[87]，选择合适的频段，并利用逆傅里叶变换回到空间域，之后的学习过程与常见的神经网络无异；另一个选择是修改编码器的结构从而使模型尽

可能多的学习特定频段的信息，对于微调过程来说，尽可能的减小可调参数量是有益的，而修改微调时的结构可以同时兼顾频率的选择。小样本学习中常用的编码器是卷积神经网络，由于其高效的视觉归纳偏置和高效微调使其在 Vision Transformer^[29] 几乎统治了所有机器学习领域的同时，还可以保持在小样本学习上的先进性能。

深入思考卷积神经网络的工作原理，卷积层是 CNN 提取视觉特征的主要模块。卷积操作有一个很好的性质，即空间域的卷积等价于频率域的哈格马积，首先证明卷积定理。

定义 3.3 给定两个函数 f 和 g ，它们在实数域上的卷积定义为

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

定义 3.4 记 $\mathcal{F}$ 为傅里叶变换，函数 f 和 g 的傅里叶变换定义为

$$\mathcal{F}\{f(t)\}(\omega) = \int_{-\infty}^{\infty} f(t)e^{-i\omega t}dt$$

定理 3.5 (卷积定理) 如果 f 和 g 是两个可积函数，那么

$$\mathcal{F}\{f * g\}(\omega) = \mathcal{F}\{f\}(\omega) \cdot \mathcal{F}\{g\}(\omega)$$

既然卷积层是视觉特征的主要提取算子，而卷积操作又满足卷积定理，沿着这个思路继续思考，借助可学习的卷积核定向引导卷积核学习特定频率的信号是可行的。通过卷积定理可以知道，对卷积核 f 和数据 g 先卷积计算再做傅里叶变换后进行低频提取等价于先对卷积核 f 进行傅里叶域的低频增强再做卷积计算。也就是说，如果想要增强卷积核的低频提取能力，就要增强卷积核的频谱中的低频分量。如图3-4所示，低通滤波器在空间域只允许图像的低频通过，在频率域的表现则是低频很强的傅里叶谱与原始图像的傅里叶谱做哈格马积。因此，可以通过只微调卷积核参数傅里叶谱的低频部分，就可以使得卷积核定向学习过滤图像低频的能力。进一步地，0Hz 直流分量在几乎所有数据中的能量都是最大的，增强卷积核的中低频信号可以简化为增强卷积核的直流分量，就可以达到目的。基于此，本文在卷积核的频谱的 0Hz 分量上加上一个可学习的参数，该参数在微调过程中学习，以此方式针对性的增强卷积核的低频提取能力，同时保持整个网络的预训练参数冻结。根据逆傅里叶变换，对卷积核的频域的 0Hz 分量加上一个实数，等同于在卷积核的空域的每一个元素上加上相同的数，该实数的值等于频率域可学习参数在空间域元素数量和的均值。这是一个很高效的微调手段，通常情况下，卷积核为 3×3 、 5×5 、 7×7 的方形，因此此方法的微调参数量仅占总卷积核参




图 3-4 低通滤波器的傅里叶谱自身的低频部分很强，反之理想高通滤波器的傅里叶谱自身的高频部分很强。左列为原始数据，中间列为滤波器，右列为滤波后数据。第一行为空间域数据，第二行为频域数据。图源自 Kris Kitani

数量的 2%-11%，同时考虑到 1×1 的点卷积并没有起到在空间域上的特征提取作用，因此不对 1×1 设计微调。

这种微调技术的路线是一种部分微调手段，已有工作 [88] 证明在小样本学习上，部分微调比全参数微调能取得更好的效果，不过这与 Luo 等人 [55] 的工作的结论不同，这可能是前者未能遵循后者在实验上的设定造成的。总之，部分微调技术已经展现出了出色的小样本学习能力，这也很好理解，小样本支持集中的少量数据并不需要全量微调去适应，这有利于提高参数估计效率以及防止过拟合。

图3-5展示了被命名为 DC Adapter 的部分参数微调技术的实现细节，通过每个通道的卷积核对应一个实数可学习参数的方式，使得微调的消耗大量减少。此外，这种技术只能用作模型微调，不能用作预训练，因为微调过程只微调低频信息处理能力是建立在已有的预训练模型参数已经掌握了全频的信息提取能力的基础之上的。同时因为本文假设卷积核的每个通道都是单独的进行特征提取，因此对于一个 $C \times H \times W$ 的卷积核权重，需要学习的额外参数量是 C 。这与 Cai 等人 [89] 提出的 On-device 微调、Zaken [90] 提出的仅偏置微调是不同的，DC Adapter 的微调参数量要高于这二者，未来 DC Adapter 的微调效率潜力还待进一步的研究。

表3-5展示了 DC Adapter 的微调效果，可以发现在 Meta-Dataset 上的其中 7 个数据集上的表现都非常有效（排除了域外的 Fungi [91] 与 Traffic_Sign [92]，因为这两个数据集不满足采样条件），所有测试数据集上的结果都高于不进行模型微调的结果，并且都十分接近，基本达到了全参数微调 99% 以上的性能，依照 Luo 等人 [55] 的结论，全参数微调应是最优的测试阶段算法，因此 DC Adapter 具备高效微调上




图 3-5 DC Adapter 设计图，对卷积核每个参数加上一个实数等于在其频域的直流分量加上相同的实数

的先进性。

表 3-5 DC Adapter 实验结果，模型在 Meta-Dataset 上的每个测试数据集上采样了 40 个任务，汇报结果为所有任务的平均值。第一行为直接测试结果，第二行为全参数微调结果，第三行为高效微调结果。结果保留 2 位小数

	Omniglot	Aircraft	CUB	DTD	QuickD	VGG	MSCOCO	Avg
Linear Probing	95.07	46.87	60.60	61.33	71.63	84.30	66.87	69.52
TSA ^[73]	95.83	53.70	63.86	69.20	71.73	87.03	68.11	72.78
Full FT	96.26	54.10	64.46	69.36	71.73	87.20	68.16	73.04
DC Adapter	95.80	53.53	64.13	69.33	71.90	87.09	68.13	72.85

再次回顾卷积定理，因为卷积核的平均值等于傅里叶谱的 0Hz 分量实部，如图3-6在卷积神经网络的模块设计中，也存在一个平均池化的操作，即一般的编码器卷积网络都会在最后获得的特征向量上沿着空间维度做平均池化，这等价于去除了特征的所有交流分量，只保留直流分量。这再一次表明神经网络特征中低频信号对于分类任务的重要性。

进一步，本文做了全量微调和 DC Adapter 微调的计算消耗对比，如图3-7所示。时间消耗上，由于两种方法都需要全部网络的前向传播与反向传播，差别仅在要进行梯度下降的参数不同，因此最耗时的反向传播梯度计算并没有节省，仅




图 3-6 池化操作与频率原则的关系

在梯度下降一步省去了部分时间，因此时间消耗的下降并不明显，单步优化时间从 185 毫秒下降至 177 毫秒，下降幅度仅 4.3%。从运行时显存的消耗来看，由于不需要存储 99% 以上参数的优化器状态，这一部分通常占据了运行时显存的 60%，因此显存的节省效果非常明显，显存占用从 914 兆字节降低至 658 兆字节，下降幅度约 28%。




图 3-7 两种方法微调消耗对比，左图为时间消耗，右图为运行时显存中优化器消耗。实验中网络为 ResNet12，使用 5-shot 微调

考虑到 DC Adapter 是从小样本角度设计的算法，那么当支持集变大时，也就是 shot 数变大时，算法的结果该如何变化？本文在 MSCOCO 数据集上进行了从 1-shot 到 32-shot 的全参数微调与 DC Adapter 微调算法的比较实验，如表3-6所示，可以看出当 shot 数很低的时候，也就是支持集中样本极少时，DC Adapter 算法微调后的结果甚至可以超过全参数微调，这一点很好理解，1-shot 下并不需要动那么多的参数，而是只需要针对性的调整一部分低频即可。但是当 shot 数增大时，虽然 DC Adapter 仍然能够紧跟全参数微调的性能，但是之间的差距在逐渐显现，说

明当支持集样本数目变多时，仅从低频信号中学习是不够的，类相关知识需要高频信息的补充，这与 Xu 等人 [85] 关于优化过程的观察是一致的，即模型会先学习简单的低频信息，再学习更难的高频信息。

表 3-6 不同 shot 数下两种算法对比，实验在 MSCOCO 数据集上采样 40 个任务进行

MSCOCO	1-shot	2-shot	3-shot	4-shot	5-shot	8-shot	16-shot	32-shot
Full FT	49.86	57.06	65.73	65.33	68.27	74.93	75.60	83.33
DC Adapter	50.00	56.67	65.87	64.93	67.60	75.06	75.20	82.93

3.3.2 一个量化的视角

回顾 DC Adapter 方法，可以发现其实该方法把微调学习过程简化为一个单值的学习过程。具体来说，每一个卷积核的每一个通道的所有参数都仅有一个可学习参数来调节，这种单值微调除了上节中时间和显存优势、性能保持优势之外，还具备一个很好的性质，即每次微调的参数增量都仅占全参数的 1% 左右，这对于 ResNet12 这种小模型来说，对于每个任务全参数微调一个新的 ResNet12 网络可能可以忍受，但是在 大模型时代，诸多视觉基础模型如果要微调，还要为每个新任务保持一个全套的新参数，这对于存储的压力是巨大的。通常，一个 7B 参数量的基础模型对于硬盘空间的需求为 24GB 左右，而 7B 也仅仅只是大模型的入门级参数量，为很多个新任务微调基础模型并保存其全新微调版本是存储不可接受的。

增量式微调配合量化技术可以大大缓解这一难题。一些增量式微调技术如 LoRA [93] 可以利用参数增量的低秩假设从而为每一个模型参数学习一个低秩近似，而完成这种低秩近似所需的参数量可能只是原有参数量的 1/8；另一个最新的大模型全参数微调工作 [94] 则是证明了参数的梯度是低秩的，因此可以依靠低秩近似大幅的减少优化过程中的优化器状态存储从而极大地减少对显存的需求。因此增量式微调技术是现行社区追求的热点，而 DC Adapter 也同样是一种增量式微调技术，这与社区关注点一致。另一方面，仅仅靠增量式微调并不足以彻底缓解微调负担重的难题，Liu 等人 [95] 最新开发了一种量化技术 BitDelta，该算法建立在增量式微调技术的基础上，将 Transformer 微调时的增量矩阵以其平均值代替，但保留其符号，形成了一种单值微调手段。从图3-8可以看出，对于 Transformer 中的任一参数矩阵，都先使用全参数量微调保证其微调精度（不采用 LoRA 的原因是其证明参数增量并非低秩，因此低秩近似存在较大误差），其次将去微调之后的参数增量矩阵求其绝对值平均值并将该值作为对于原参数矩阵中每一个元素的微调值，但保

留每个参数增量矩阵位置的符号以保持其优化方向。该算法可以极大的降低新微调模型的参数存储量，通常一个 7B 的基础模型，通过此方法微调存储后的参数增量文件仅为数百兆字节，这是完全可以接受的。BitDelta 也是一种单值微调算法，与 DC Adapter 在 CNN 上的单值微调算法不谋而合。




图 3-8 BitDelta 算法示意图，引自 Liu [95]

是否可以从量化视角来理解 DC Adapter 的有效性呢？

作为一个普遍意义上的认识 [96,97]，量化通常被认为是优化过程的正则化器：量化后的参数去除了大量高频信息，使得模型所表达的函数更加平滑，起到了一种类似正则化的效果。如果着眼于小样本微调上，DC Adapter 这种单值微调实际上是对全参数微调在任一卷积核通道上的量化，这与 BitDelta 的思想是一致的。DC Adapter 的作用等价于对卷积核参数在任一通道上施加了正则化，而小样本微调由于其支持集样本的匮乏，梯度信号本就含有大量噪声，DC Adapter 抑制了这种梯度噪声，保证了在小样本条件下的微调稳定性。

3.4 本章小结

本章从超参数敏感性讨论了小样本学习中关于分布偏差的问题，在超参数角度通过集成学习缓解了这种偏差；进而从分布偏差考虑到小样本的微调过程中的知识匮乏现象，导致特征估计不准，并用一个研究案例支持了这种观点。进一步的，从知识迁移的角度考虑微调过程，提出了低频先验增强的微调算法，体现了在性能、时间、显存的最佳权衡，并从傅里叶和量化的角度分析了所提出微调算法的有效性。

第四章 大模型的提示小样本学习

4.1 提示学习与隐式概率建模

前文已经说明，在本章中，大模型一词涵盖两类模型，一是在丰富数据集上进行各种方式预训练的基础模型，例如 CLIP、Dinov2、SAM、DAM 等，这些模型仍然停留在度量学习的范畴内；二是当下社区火热的生成语言/多模态模型。

基础模型适应下游任务的形式本质上并没有改变，仍然是编码器加上任务头的形式，这在 Dinov2^[58] 的论文中已经充分的得到了体现。但基础模型与经典 ImageNet 训练的 ViT 不同的地方在于，往往它们的模型规模更大，最关键的是在非常丰富的数据上进行了预训练。例如，GPT-2 的训练数据量在 40GB 左右，CLIP 的数据集规模约为 4 亿，Dinov2 的数据规模在 1 亿 4 千万左右，SAM 的训练数据规模约为 110 亿图像掩码，这种规模的预训练数据使得模型可以掌握足够的预训练知识，甚至是部分世界知识。因此，通常意义下的下游任务，很有可能在预训练阶段已经学习过了，并不属于域外。当基础模型需要适应下游任务时，更新模型本身可能带来潜在的不利影响，因此这类基础模型的下游适应形式出现了从“模型适应数据”到“数据适应模型”的转变。一个最具有代表性的形式是提示学习，即将输入给基础模型的提示信号添加可学习的编码前缀，让下游任务的数据，在特征空间上，与预训练模型的已有知识对齐。一个自然语言处理领域的例子是前缀提示学习^[26] 将 Transformer（GPT2）的输入序列的前部添加一个可学习的编码，使用下游任务数据学习针对于这个任务的前缀编码，学习完成之后，只要存储极其轻量化的编码即可适配该基础模型到此类下游任务。另一个视觉领域提示学习的代表性工作是 CoOp^[17]，以相似的思想适配 CLIP 模型到下游的开放词汇分类任务上，引出了之后的一系列工作^[28,98]。但需要指出的是，基于 CLIP 的各种提示学习工作，在评估上存在一个关键性错误，即仅仅只取了 3 个随机种子取平均值，这将导致 CoOp 之后的一系列工作在性能上的比较都是无意义的（置信区间无法分开）。

生成大模型的小样本学习具体指的是在输入给大模型提示（Prompt）时，给出一些新的任务的数据-标签对，从而间接提示大模型本任务的类型。这个过程并不需要梯度下降和模型参数更新，而仅通过调节输入输出示例来执行任务，但却可以成功地推理出给定几个例子之后的任务属性。小样本提示在帮助大模型解决复杂任务上展示出了相对出色的性能，从 Min 等人^[99] 的研究中得出，这种数据-标签对的形式对提示大模型起到了至关重要的作用。本文将数据-标签对称之为演示

数据，即对大模型起到演示示范作用的数据。需要预先说明一点的是，Transformer 的架构已经被证明^[100]可以在前向传播的过程中，求解最小二乘问题，本文认为基于自注意力与多层感知机的结构可以解决部分优化问题，以数值优化的近似解或者函数的闭式解的形式得出。

本节借助该工作中^[101]中的结论对隐式概率建模进行阐述，小样本提示被规范为大模型的隐式概率建模，即大模型的输出实际上是判定隐式概念之后的条件概率，整个推理过程可以用贝叶斯推理来解释。该工作^[99,101]提供了一个贝叶斯推理框架，用于将上下文学习理解为“定位”大模型从预训练数据中获取的潜在概念。这表明关于提示的所有组件（输入、输出、格式和输入-输出映射）都可以提供用于推断潜在概念的信息。

首先说明潜在概念的含义。潜在概念可被视为包含各种类型统计数据的潜在变量，例如，“新闻”这个词的潜在概念描述了新闻相关的单词的分布、格式（新闻的撰写方式）、新闻和主题之间的关系以及单词之间的其他语义和句法关系。一般来说，潜在概念可能是其它潜在概念的组合，它们符合某种运算规则，而这种运算规则的结果符合人类意识的判断。回到小样本提示的贝叶斯推理，依照已有的工作定义，可以将其公式化为：

$$p(\text{output}|\text{prompt}) = \int_{\text{concept}} p(\text{output}|\text{concept})p(\text{concept}|\text{prompt})d(\text{prompt}) \quad (4-1)$$

公式4-1中 concept 指的是认知范畴内的各种潜在概念类型，prompt 包含各种形式的提示内容，不仅限于小样本提示。大模型利用提示和潜在概念的联合分布估计每一个潜在概念的边缘概率分布，而同时也需要根据潜在概念和输出的联合分布去预测输出的边缘分布，这两种联合分布的知识是嵌入在海量的大模型参数当中的。

这种能力产生的原因可能来自于与训练阶段的一致性。几乎所有的大模型的训练阶段都是从序列中学习的，即给定一个序列的前缀，模型需要迭代地预测下一个单词或者符号是什么。模型可能学习到了从输入序列中预测出潜在概念，从而再从潜在概念中预测下一个令牌的贝叶斯过程。

关于小样本提示的特点，可以归纳为如下几点：

1. 输入-标签的形式对模型推理存在关键作用。

大模型需要从多个小样本提示中，推理出这是一个什么类型的新任务。例如，输入空间为 $I = \{s, s \text{ 为句子}\}$ ，标签空间为 $L = \{True, False\}$ ，因此模型可以判断出这是一个典型的二分类任务，分类标签空间为 $True, False$ 。在实验中发现，小样本提示比零样本提示有着明显更好的性能。

另一方面，为了控制变量，仅保留输入-标签的形式而不保留任何其它信息，通过消融标签的正确性，把小样本提示中的标签更换为标签空间中的随机采样，甚至直接更换为英语词语空间的随机采样，大模型依旧在这种人为噪声的小样本提示中表现出了显著强于零样本提示的结果，这直接支持了大模型可以从提示数据的形式中推理相应潜在概念的假设。




图 4-1 对小样本提示的标签进行随机扰动，其中从左至右分别为不加小样本提示（蓝色）、带正确标签的小样本提示（黄色）、扰动标签的小样本提示（红色），横轴为各类大模型，纵轴为上下文学习性能。结果引用自 Min [99]

从图4-1可以看出，即便是将小样本提示中的标签更换为完全不一致的标签空间，依然可以产生显著优于零样本提示的结果，这说明大模型从小样本提示中获取到了任务属性等信息，这对于大模型的推理是很重要的。还需要说明的是，这与监督学习的想法完全不一致，在监督学习下，如果输入-输出不存在任何统计上的对应关系，那么模型将不会从数据中学习任何知识，甚至优化过程都无法收敛。

2. 演示数据的标签分布和输入分布都很重要。

除了小样本提示的形式之外，提示中的输入分布与输出分布同样对大模型的上下文推理有明显的影响。首先讨论对输入空间的分布外扰动，如果将输入空间的文本以完全与之前无关的句子进行替换，比如将“真理报今日报道‘巴以局势’近日出现缓和迹象”替换为“今日折扣：全场八折起”，那么原先的标签“新闻”将不与输入存在任何对应关系，且这与图4-1的扰动不同，这种扰动属于分布外扰动，而图4-1的扰动仅仅只是在分布内调换了标签，但仍可以保持任务属性等基本信息。可以从图4-2从看出，这种分布外扰动对上下文学习的性能产生了很大的影响，猜想这可能是由于概念突变产生的，小样本提示中的多条提示之间、提示内输入输出之间产生了明显的概念突变，这使得大模型很难定位小样本提示在预训练

知识中的位置。对标签空间的分布外扰动同样存在着相似的结果，这里不再赘述。




图 4-2 对小样本提示的输入进行随机错误扰动，这意味着这种扰动不从输入空间中采样，而是直接从语言空间中采样。从左至右分别为正确输入的小样本提示（黄色）、同分布输入扰动的小样本提示（红色）、分布外输入扰动的小样本提示（紫色）、不加小样本提示（蓝色）。横轴为各类大模型，纵轴为上下文学习性能。结果引用自 Min [99]

3. 适当增加小样本提示对是有利的，但可能存在边际效应。

关于小样本提示的长度，一个上限是考虑到大模型上下文长度的影响。由于存在中段忽视效应 [102]，猜想这可能并不意味着提示的长度越长越好，可能存在边际效应。另一个合理的判断是小样本提示中提示与提示的一致性需要尽可能保持，尤其是在提示数量较少时。以上两条判断均符合隐式概率建模的假设。

输入：这组数字中的奇数加起来是一个偶数：4、8、9、15、12、2、1。
输出：答案是False。

输入：这组数字中的奇数加起来是一个偶数：17、10、19、4、8、12、24。
输出：答案是True。

输入：这组数字中的奇数加起来是一个偶数：16、11、14、4、8、13、24。
输出：答案是True。

输入：这组数字中的奇数加起来是一个偶数：15、32、5、13、82、7、1。
输出：答案是True。（实际上是False）

图 4-3 给定一个数学加法结果的奇偶判断任务，小样本提示并不能正确判断

小样本提示在更复杂任务上的表现依旧存在着不确定性。如图4-3中所示，大

模型虽然成功的输出了需要的格式，但其结果并不正确，这暗示着大模型的推理仍需要更有效的提示手段，如将复杂问题拆解为单独简单的小问题的思维链提示^[60]（这与计算机算法中的动态规划思想类似）等。总之，小样本提示在很多情况下很有效，如果能获得几个样本的提示，根据边际效应，就能使大模型产生令人满意的结果。

进一步的，本文从大模型视角下观察小样本学习，对比元学习和迁移学习范式下的小样本学习，可以从中获得一些见解。**元学习在世界模型起点下是有效的。**首先，关于元学习的监督微调（SFT），观察 SFT 演示数据集的结构组成，实际上是元学习的数据结构形式。尽管本文在4.1中讨论的是小样本提示在推理中的形式，但在大模型的监督微调（指令微调）阶段是一致的。参考图1-4的例子，在微调时，已经给定的提示例子等同于小样本学习中的支持集，而最后的查询则是小样本学习中的查询集。指令微调在给定几个样本-标签对的情况下判断查询的结果，并根据输出计算损失函数，这与元学习在小样本上的学习如出一辙。因此，大模型的指令微调就是大模型的元学习训练。但是在小样本问题上，元学习通常不能表现出先进性，尤其是 Meta Dataset 这样的支持集样本数量很大的基准上，基本没有任何性能优势。但是在模型的指令微调上，却能够在相对很少的演示数据（GPT3 约为 17,000）上表现出色，能够学习到演示数据内蕴含的形式信息，引导 GPT 模型对齐输出形式与风格，这说明元学习在一个足够富知识的世界模型为起点时，可以表现出有效性，最近的许多工作^[103-106]都直接证明了这一点。由于世界模型是在极大量数据上训练的，或许这也暗示着元学习在小样本问题上的局限可能是训练数据严重匮乏导致的。**小样本解决方案的选择要参考问题条件。**虽然大模型的小样本提示已经表现出了不俗的结果，但是小样本模型微调依然在很多任务（尤其是多模态任务）上是最优的选择。当需要对某一个小样本问题确定其解决方案时，如果问题条件是垂直领域或图像领域时，则应该优先考虑小模型的小样本模型微调；如果是自然语言推理等问题时，则应该考虑大模型的小样本提示或指令微调。**大模型的小样本学习需要在提示学习的框架下研究。**很显然，小样本提示旨在帮助大模型定位预训练时的知识与概念，但仍有多种其它方式亦可做到这一点。小样本提示必须要在提示学习的框架下研究，而不能只研究小样本提示，这是没有太大意义的。比如对提示的压缩^[107]就与小样本学习中的数据选择密切相关，而其并不着眼于小样本提示本身。

4.2 SAM 提示粒度一致性

分割一切模型 (SAM) [21] 是由 Meta 在 2023 年 4 月提出的一个超大规模视觉基础模型, 其通过自训练 (Self-Training) 的形式标注了 1100 万张图像与 11 亿物体掩码标签 (SA-1B 数据集), 平均每个图像标注了 100 个物体或物体部分掩码。SAM 的编码器采用 ViT 架构作为骨架, 解码器采用 DETR [108,109] 结构使得查询向量可以根据查询的需求定制学习目标。由于 SA-1B 数据集中不含有语义标签, 仅包含由 10% 数据训练的模型进行自动标注的结果, 因此 SAM 使用交互式方式进行训练。在训练过程中, 点、框、粗糙的掩码作为提示通过提示编码器编码, 形成 DETR 解码器的查询向量, 并与 SAM 图像编码器编码的图像密集特征一起输入到 DETR 解码器中, 经过解码器的信息交互, 查询向量中就包含了所需要同图像编码中查询到的信息, 后续再经过后处理, 就可以获得逐像素的掩码表示。SAM 革新了图像分割领域, 其庞大的数据集和超高的标注质量使得 SAM 成为了目前图像分割领域分割质量最高的开放世界分割器。图4-4展示了 SAM 的模型结构。




图 4-4 SAM 结构示意图, 其中图像编码器中在尾部比标准的 ViT 结构额外设计了上采样颈 (Neck), 引自 SAM [21]

相对于传统的闭集图像分割算法, SAM 需要提示的输入来启发模型如何进行分割。虽然这种提示只是以点、框等形式输入, 既不是大语言模型的提示类型, 也不需要在此提示上进行隐式建模, 但在本研究案例中, 本文希望以提示工程为中心, 模型微调为手段, 去研究当前基础模型的学习过程。这与大语言模型的小样本提示在指令微调中的作用是相似的, 因此可以举一反三, 为大模型的小样本提示与指令微调提供观察。

SAM 被提出后, 社区围绕 SAM 开展了跨各种范围的研究 [24,110]。其中, SAM 的提示一致性问题与语义缺失问题成为了研究的焦点。由于 SAM 的训练数据中并

不含有语义，因此 SemanticSAM^[24] 通过联合训练没有语义标签的 SA-1B 和有标签的闭集分割数据集，希望能够将语义泛化到真实世界中，但本质上还是一个闭集算法。另一个备受关注的 consistency 问题指的是提示的歧义问题，当用户在图像上点击一个位置之后，对于同一个点击的提示，SAM 会生成三个不同粒度的分割结果，如图4-5所示，这种歧义导致 SAM 很难应用到对齐场景中，一个最简单的事实是即便 SAM 如此强大，可它连最基本的实例分割都无法完成。SemanticSAM^[24] 试图解决这个问题，它利用 SA-1B 数据集中原有的 6 种级别的粒度标签，分别训练了 6 个额外的粒度感知提示编码，用户想要 SAM 分割成什么粒度级别，就使用合适的粒度感知提示编码，加到原本的提示编码上，达到粒度粗糙可控的目的。但是由于 SA-1B 的 6 种级别的粒度不具备任何分级标准，例如如果用户想要分割出全部的物体级别的掩码，却找不到一个粒度感知编码对应“物体”这个概念，这本质上依然没有解决最原始的问题。目前该问题仍然无法得到解决，任何一种提



图 4-5 SAM 提示歧义示意图，对于同一个点提示，SAM 产生了三种合理但置信度不同的分割，引自 SAM^[21]

示都不能保证 SAM 会给出粒度一致的分割结果，这已经成为缺乏语义之外 SAM 的最大问题。粒度是无法用逻辑定义的，是一个相对概念，所以使用数据定义几乎是唯一的途径。下面本文将首先分析 SAM 的特征空间特点，并利用分析结论设计可行性方案，并讨论这对小样本提示学习的启发。

SAM 是一个出色的开放世界边缘检测器。本文对 SAM 的图像特征两两之间计算了余弦距离，如图4-6的 d，可以发现，图像中的各处边缘，即便是物体上细小的边缘与物体间很小的缝隙（如地板），都被 SAM 很好地检测到了。然而，不同的区域却显示出了相似的强度值，如狗的身体上的特征相似性与人的腿部上的特征相似性很接近，这又说明 SAM 并不具备区分不同物体的能力。综上两点可以得出，SAM 只是一个很出色的开放世界边缘检测器。进一步观察，a 中红色框对应的图像部分在 t-SNE 可视化中是蓝色的一簇，和 b、e 作为对原始图像、图像 SAM 特征分别进行 OTSU^[111] 分割的结果，显示出了明显的差异。由于 OTSU 只是根据像素分布选择阈值，所以并不具备物体感知能力，这就导致了 b 中狗的身体和人的腿部的内部像素被分割到了不同的掩码中，然而 e 却表明，SAM 的特征却很好




图 4-6 a 表示原始图像，d 表示原始图像的 SAM 特征编码，b、e 表示对原始图像、图像 SAM 特征分别进行 OTSU^[111] 分割，c 表示图像特征的 t-SNE 可视化，其中蓝色部分对应原始图像红色框部分对应的图像特征

的表达了狗身体和人腿部内部的一致性，因此其 OTSU 分割保持了狗身体上和人腿部内的像素的分割一致。这说明 SAM 能够感知到“什么是一个物体”，所以可以检测出很好的边缘信息。这启发社区 SAM 实际上具备分割出物体的天然条件，但需要非常精准的提示信息。




图 4-7 从左到右分别为 SAM 图像特征与平均特征、狗身体某一点处特征、狗边缘一点处特征的相似度

SAM 特征空间为簇形态表达，不同物体、边缘隶属一簇。观察图4-7，当选中的锚特征点是狗的身上某点时，狗身体上的部分都与该点强相似度，而与周围所有物体环境区分，这说明虽然 SAM 不具备区分语义物体的能力，但是它可以把一个物体的图像特征编码到一起，且以簇形态组织；当锚特征点为物体边缘时，该物体边缘整体都会强响应，整个图像的边缘也会有一定响应，而边缘两侧物体都

不会出现强响应，说明 SAM 把边缘也单独编码到一大簇当中，且不同的边缘隶属于大簇内的不同小簇。这可能暗示着可以通过检测特定的簇以及分析簇分布来引导物体分割。




图 4-8 SAM 特征空间的 Logit Lens 观察，从左到右分别为编码器不同层输出的特征，其所代表的特征空间的距原点距离、张开角度、欧氏距离直径

上面的分析启发本文对簇的分布进行分析，在分析簇分布之前，首先需要了解整个特征空间随着学习优化的变化规律。Logit Lens^[112]是观察 Transformer 类模型在不同层上表现进化的工具，在 GPT3^[18]中也用作“猜测-细化”假设的验证。在图4-8中，选用的 ViT-B 模型具备 12 层，对每一层的输出计算整个输出特征空间的特点，可以分析出有用的结论。本文对特征空间平均点距离原点的欧式距离、以特征空间为主体的超球面的张开角度和欧式直径进行计算，发现随着浅层到深层的编码，特征空间超球面逐渐远离原点，在浅层逐步张大角度，并始终在增大超球面直径。通过这个实验，本文建模出了 SAM 特征空间从浅层到深层网络的演化过程：逐步加速远离原点的同时，在球面径向方向上逐步扩张，而在球面切向上仅在浅层扩张，深层保持稳定，最终形成类似超椭球的特征空间。这种空间变化过程给空间内的簇分布的形成提供了条件，有利于簇形态的形成。

现在继续深入特征空间内部，观察簇形态的形成过程。本文在对不同层的输出特征进行了核密度估计，这是一种无参的概率密度估计，可以在提供尽可能多的样本的情况下，模拟出这些样本所代表的真实分布的近似，而并不需要提供分布的先验信息。在图4-9中，左图表示不同层的核密度估计对于自身的概率估计随着网络的深入而减小，这是一个很意外的结果，因为这往往意味着特征空间在“整体上”变得更加均匀，这与之前的簇形态观点完全不同。然而，根据核密度估计的性质，如果被估计的分布的碎片化越严重，即簇形态越明显，这等价于在许多分布的组合上做核密度估计，然而整个组合分布的总概率恒为 1，也会导致自身总体在核密度估计的概率分布上的估计变小（分母变大）。这启发作者进行了下一个实验，在不同层的核密度估计中，计算某一簇关于自身核密度估计与总体核密度




图 4-9 SAM 特征空间的簇形态形成过程，左图为不同层特征的核密度估计结果；右图为不同层特征的核密度估计结果，绿线为某一簇关于自身核密度估计的概率估计，红线为某一簇关于总体核密度估计的概率估计

估计的概率值，如图4-9右侧所示，绿线代表某一簇关于自身的核密度估计的概率，随着网络的加深而逐渐升高，红线是关于总体核密度估计的概率，出现下降的结果符合左图的推测。综合可知，随着网络的加深，特征空间中的簇在逐步收紧，而簇之间的距离则在变大；另一个发现是似乎随着网络层数的加深，这种簇形态演变趋势呈现出边际效应。这可能意味着 SAM 的特征编码器不同层之间的差异并不大，可能满足 Random Guess - Refine 性质，这在 Transformer 类模型中十分普遍。




图 4-10 左图为不同层特征的可视化结果，右图为不同层特征关于最后一层特征核密度估计的概率

SAM 特征编码器服从 Random Guess - Refine 性质。上文推测，SAM 的特征编码器的不同层的特征表达之间可能差异较小。因此设计了图4-10的实验，首先可视化出不同层特征，在视觉上仅在前几层 SAM 的特征表达就已经足够好，这验证了 SAM 特征编码器服从 Random Guess - Refine 性质的假设，同时也意外的发现 SAM 特征编码器的最后一个上采样模块实际上对于各层特征都匹配，尽管它是在最后一层特征上训练的，这说明不同层之间的特征空间差别并不大。图4-10右图定量的支持了这个观点。对 SAM 特征的最后一层做核密度估计，然后从第一层到

最后一层的特征分别在该核密度估计上计算概率，发现概率是沿着层数单调递增，说明 Random Guess - Refine 性质成立。这可能暗示着对于 SAM 的使用可以适当的采用浅层表征，从而节约设备资源。



图 4-11 SAM 解码器的空间-物体权衡，调节解码器中交叉注意力上关于空间信息和物体特征信息的权重，可以实现空间-物体权衡

SAM 解码器是空间-物体权衡的阈值器。基于 SAM 编码器的良好性质，本文假设在解码过程中，解码器可能根据提示所在点的特征，与特征空间中的其它特征相比较，比较时不仅需要考虑两点在空间域上的距离（这基于图像都是缓慢过渡的假设），还需要考虑两点之间的特征相似度（这基于表征学习的视角），这也就导致了 SAM 解码器在分割时的空间-物体权衡，如人的头部虽然和人的腿部距离较远（空间相似度低），但是由于同属一个物体（特征相似度高），依然可以被整体分割出来；而人的手部尽管和喂食盆距离很近（空间相似度高），但不属同一个物体（特征相似度低），则不会被分割出来。总体而言，解码器在簇形态良好的特征空间上利用空间-物体权衡起到了一个阈值器的作用，这对于控制解码器行为（如分割粒度）提供了一个好的思路。

参考上面的分析结果，本文设定项目的目标为如何通过给定的粒度提示数据从而泛化到其它类语义的粒度上去。具体来说，以人体分割数据而言，SAM 需要去适应人体分割的粒度，但是人体的各个部分（如头部、手臂、腿部等）是不同的语义类别，但是这些类别又同属于一个粒度，即人体的部分。SAM 需要在少量语义类别的分割数据上学习（如：左侧手臂），进而能够感知手臂的分割粒度，并将粒度概念传播到人体的其它语义部分上去（如头部），尽管这些语义部分在微调期间并没有出现。

由上文对 SAM 的性质分析可知，SAM 具备物体感知的能力，但是无法区分语义。SAM 的解码器充当了阈值器的作用，如果使得 SAM 要适应下游人体分割数据集的粒度，仅仅微调解码器是不够的，阈值的调整并不能完全适应 SAM 编码器对人体各个部分的编码所构成的簇状特征空间，因此仍需要调整编码器的参数。通过将编码器特征空间映射通过可学习参数的方式映射到另一个线性空间，在这

个新的线性特征空间中，粒度相同的语义部分在特征聚合度、空间距离上也相似，从而可以借助粒度提示调整解码器实现不同语义同粒度部分的分割。

基于此考虑，本文设计了一个 SAM 粒度提示微调适应算法，命名为 SAM-PT。在提示编码器中从头学习一个粒度感知编码的基础上，通过多层感知机将原有特征空间映射到新的空间中，这样做的目的是使得特征空间在学习给定类语义粒度的基础上之后，能够传播到不同语义下的同粒度数据上去，进而搭配粒度提示编码，通过基于查询的交叉注意力（Query-based Cross Attention）实现信息传递。实验数据集选用了人体分割和解析数据集 CIHP，该数据集中包含 38280 张图像，其中训练集 28280 个样本，验证集 5000 个样本，测试集 5000 个样本，但只公开了训练集与验证集的标签。数据集中包含 19 类不同的人体语义部分，包括但不限于头部、眼镜、左手臂、右手臂、左腿、右腿等，图像均为自然图像，且存在语义重叠和视觉干扰，分割的难度很大。在本文中，依照小样本学习的设定，将训练集划分为“面部、头发、躯干、上衣、左手、右脚、左腿、连衣裙、袜子、太阳镜、围巾”，将测试集划分为“右手、左脚、右腿、外套、裤子、帽子、手套、裙子”，训练集和测试集之间不存在交叉。这与小样本学习的设定存在少许出入，原因是支持集与查询集并不属于同一语义而是同一粒度，实验中 shot 数为 30。实验结果见表4-1，左表展示了 SAM-PT 可以在同语义同粒度的不同样本间实现泛化，右表表示在更难的实验条件下，充分考虑了 SAM 本身特点的 SAM-PT 粒度提示微调可以学习到不同语义同粒度数据的泛化，表4-1表示相较于原始 SAM，SAM-PT 在交并比（IOU）和边缘交并比（Boundary_IOU）上都实现了明显的提升，验证了算法的有效性。

表 4-1 SAM-PT 具有良好的泛化能力

a SAM-PT 同语义同粒度泛化结果			b SAM-PT 不同语义同粒度泛化结果		
	IOU	Boundary_IOU		IOU	Boundary_IOU
SAM	0.7340	0.7036	SAM	0.7624	0.7559
SAM-PT	0.7899	0.7609	SAM-PT	0.7995	0.7886

本节给出了 SAM 基础视觉分割模型和提示学习相结合时的研究案例，从中可以获得一些对于大模型的小样本学习的启发。小样本提示学习需要深入研究基础模型的特点与性质。除了本节中基于簇形态的分析案例之外，Claude 2.1 [113] 在“针在干草堆测试”（Needle In a Haystack）中出现的行为也支持这一观点。Claude 2.1 倾向于理解并忽略掉测试中的针，并认为这是无意之间加在长上下文提示中的句子，这并不意味着它在这方面能力欠缺，而仅仅需要增加一句提示词“这是与

上下文中最相关的一句话”，即可激活 Claude 2.1 模型在这一项测试中的准确率上从低于 20% 提高到 98%，这说明了提示学习需要建立在针对大模型特点的基础之上的观点。

4.3 本章小结

本章阐述了小样本学习在大模型中的应用形式：小样本提示，并对小样本提示的贝叶斯推理进行了理论上的建模和分析，说明了小样本提示应该具备的特点，如一致性等。同时，思考了大模型时代下的小样本学习应该如何研究的问题，认为元学习在世界模型起点上的良好表现暗示着小样本元学习范式的较差性能可能是数据匮乏导致的。最后给出了一个研究案例，通过研究提示学习在基础模型中的优化，对提示学习与小样本实际应用时的方案选择给出了观点。

第五章 总结与展望

5.1 全文总结

本文从小样本学习经典范式的重新思考入手，证明了训练-测试两阶段的割裂性，并利用两阶段独立分析的相关结论与见解切入，分别研究了测试阶段的超参数敏感性问题、高效模型微调算法和大模型视角下的小样本学习，并将其作为本文的核心内容详细阐述。最后，本文思考了小样本学习在接下来一段时间研究的发展方向，并提出了一些要点，这一部分是作者目前对于小样本学习的核心观点。

首先，作为反思性工作，本文发现基于元学习的小样本经典范式并不总能在所有数据集基准上取得先进性能，这可能暗示着元学习范式的局限。同时，一部分非元学习算法达到了意外的先进性能。根据以上两点，本文通过分析二者之间的区别提出了训练-测试两阶段可能割裂的假设，并通过了大量实证证明。紧接着，发现了在训练阶段和测试阶段不同的特点，包括预训练类别的贡献显著和测试时的超参数分离设定等等。这些结论和见解启发了之后的工作。

其次，着眼于元测试阶段的高效模型微调。首先从非线性度量的研究案例再次验证了之前的结论，之后从超参数的敏感性出发，得出小样本条件下的微调具有天然的优化局限性。因此，研究结果启发了局部模型微调的低频先验增强算法，并作为一种高效单值微调算法，本文从傅里叶角度和量化角度对其做出了解释。

随后，着眼于训练阶段的基础模型，本文分析了当前大模型热潮下的小样本学习。从提示学习和概率建模的角度对基础模型和生成模型的小样本提示的作用做出了解释，并从大模型视角对小样本学习进行了思考，本文认为大模型下的小样本学习应当上升到元学习与提示学习的层面去研究，而不再需要单独分析其本身。

本文最后提出了关于小样本学习的未来展望，小样本问题是一个很关键的问题，但它不应该在机器学习目前的进展下被考虑，而是要与持续学习、OOD 检测一同形成一个共同的任务体系。

但本文仍然具有很多局限性，包括但不限于实验设定中的样本数较少、未能对非线性距离度量在不同预训练模型和下游数据集上进行深入分析、超参数集成学习的原理性理解仍需加深等，这将留作未来工作。

5.2 展望小样本学习研究

展望小样本学习研究，作为度量学习研究中的一部分，小样本问题已经被较为深入和全面的在度量学习体系下进行了研究。元学习和迁移学习作为第一个十年的成熟方案，在小样本领域发挥了重要的作用，而可以预见的是，小样本提示配合大模型将是小样本学习的下一个热潮，这也就是当下备受关注的上下文学习，这将成为未来一段时间的小样本问题解决方案。小样本提示在大模型配合下是一种主流的形式，而小样本微调则是配合小模型的最佳形式。

换一个角度，如果重新思考小样本学习之于机器学习的意义会发现，小样本学习实际上研究度量学习或者是生成模型的一扇窗户。未来的小样本研究应该分为两个方向：

1. 研究小样本学习的本质问题，即“Many-shot”退化到“Few-shot”中到底发生了什么？这也是机器学习本质的问题。这个问题目前仍然没有被分析的很清楚，虽然已有少量工作在此领域探究，但是仍然没有接触到本质。

2. 开放世界学习。小样本学习可以与持续学习、OOD 检测构成一个任务体系，即将小样本学习置于开放世界的框架下考虑问题。单独研究小样本问题在闭集应用上已经较为成熟，而对于开集应用来说是没有意义的。但目前的问题在于，持续学习的梯度范式从理论上注定不会是一个完美的解决方案，而即便是大模型在梯度范式下的持续学习也出现了遗忘现象^[114]，这预示着持续学习的范式亟待变革，而小样本学习的限制注定会对循环中的 OOD 检测造成不利影响，后者需要大量域内样本约束模型的决策边界。目前，开放世界问题的研究仍然任重道远。

3. 上下文学习。大模型的世界知识已经足够丰富，小样本提示如何激发大模型的针对性知识，如何选择小样本提示的数据质量，以及如何配合更广泛的提示学习框架应用都是需要被探索的方向。

致 谢

感谢文中所涉及工作的合作者们，祝各位合作者工作顺利。感谢高联丽老师在硕士生期间的悉心指导，感谢实验室行政肖虹、童娅丽，计算机学院学生科叶丹、研管科曾瑞、外事秘书蒋维维等多位老师的帮助，祝各位老师生活顺心，诸事顺遂。感谢香港大学齐晓娟老师、HKU CVMI 实验室师兄师姐毫无保留的指导与帮助。

感谢成都。这里，是“窗含西岭千秋雪”的山川美景，是“万户千门入画图”的烟火人间。吃不腻的川菜，看不完的星河，蓉城以它的包容吸纳三千年历史，成为了一座我所见过“男女最平等、生活最安逸、情感最丰富”的城市。

期待与成都再会。

参考文献

- [1] Wiener N. Cybernetics or control and communication in the animal and the machine[M]. MIT press, 2019.
- [2] Specht D. F, et al. A general regression neural network[J]. IEEE Transactions on Neural Networks(TNN), 1991, 2(6): 568-576.
- [3] Harnad S. The symbol grounding problem[J]. Physica D: Nonlinear Phenomena, 1990, 42(1-3): 335-346.
- [4] Krizhevsky A, Sutskever I, Hinton G. E. Imagenet classification with deep convolutional neural networks[J]. Advances in Neural Information Processing Systems(NeurIPS), 2012, 25.
- [5] Chui M, Yee L, Hall B, et al. The state of ai in 2023: Generative ai' s breakout year[J]. McKinsey & Company, 2023, 0.
- [6] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [7] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. The IEEE Conference on Computer Vision and Pattern Recognition(CVPR), 2016, 770-778.
- [8] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]. 2009 IEEE Conference on Computer Vision and Pattern Recognition(CVPR), 2009, 248-255.
- [9] Hornik K, Stinchcombe M, White H. Multilayer feedforward networks are universal approximators[J]. Neural Networks, 1989, 2(5): 359-366.
- [10] contributors W. Efficiency (statistics), 2023.
- [11] Kraeuter A.-K, Guest P. C, Sarnyai Z. The y-maze for assessment of spatial working and reference memory in mice[J]. Pre-clinical models: Techniques and protocols, 2019, 105-111.
- [12] Fei-Fei L, Fergus R, Perona P. One-shot learning of object categories[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence(TPAMI), 2006, 28(4): 594-611.
- [13] Vinyals O, Blundell C, Lillicrap T, et al. Matching networks for one shot learning[J]. Advances in Neural Information Processing Systems(NeurIPS), 2016, 29.
- [14] Touvron H, Vedaldi A, Douze M, et al. Fixing the train-test resolution discrepancy[J]. Advances in Neural Information Processing Systems(NeurIPS), 2019, 32.
- [15] Trabucco B, Doherty K, Gurinas M, et al. Effective data augmentation with diffusion models[J]. arXiv preprint arXiv:2302.07944, 2023.

- [16] Radford A, Kim J. W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]. International Conference on Machine Learning(ICML), 2021, 8748-8763.
- [17] Zhou K, Yang J, Loy C. C, et al. Learning to prompt for vision-language models[J]. International Journal of Computer Vision (IJCV), 2022.
- [18] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in Neural Information Processing Systems(NeurIPS), 2020, 33: 1877-1901.
- [19] Chen Z, Liu B. Lifelong machine learning[M]. Springer, 2018.
- [20] Luo X, Xu J, Xu Z. Channel importance matters in few-shot image classification[C]. International Conference on Machine Learning(ICML), 2022, 14542-14559.
- [21] Kirillov A, Mintun E, Ravi N, et al. Segment anything[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2023, 4015-4026.
- [22] Yang L, Kang B, Huang Z, et al. Depth anything: Unleashing the power of large-scale unlabeled data[J]. arXiv preprint arXiv:2401.10891, 2024.
- [23] Caron M, Touvron H, Misra I, et al. Emerging properties in self-supervised vision transformers[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2021, 9650-9660.
- [24] Li F, Zhang H, Sun P, et al. Semantic-sam: Segment and recognize anything at any granularity[J]. arXiv preprint arXiv:2307.04767, 2023.
- [25] Liu X, Ji K, Fu Y, et al. P-tuning: Prompt tuning can be comparable to fine-tuning across scales and tasks[C]. The 60th Annual Meeting of the Association for Computational Linguistics(ACL), Dublin, Ireland, 2022, 61-68.
- [26] Li X. L, Liang P. Prefix-tuning: Optimizing continuous prompts for generation[C]. The 59th Annual Meeting of the Association for Computational Linguistics(ACL), Online, 2021, 4582-4597.
- [27] Jia M, Tang L, Chen B.-C, et al. Visual prompt tuning[C]. European Conference on Computer Vision(ECCV), 2022, 709-727.
- [28] Zhou K, Yang J, Loy C. C, et al. Conditional prompt learning for vision-language models[C]. The IEEE/CVF conference on Computer Vision and Pattern Recognition, 2022, 16816-16825.
- [29] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [30] Tolstikhin I. O, Housby N, Kolesnikov A, et al. Mlp-mixer: An all-mlp architecture for vision[J]. Advances in Neural Information Processing Systems(NeurIPS), 2021, 34: 24261-24272.

-
- [31] Yu W, Luo M, Zhou P, et al. Metaformer is actually what you need for vision[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2022, 10819-10829.
 - [32] Peebles W, Xie S. Scalable diffusion models with transformers[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2023, 4195-4205.
 - [33] Koch G, Zemel R, Salakhutdinov R, et al. Siamese neural networks for one-shot image recognition[C]. ICML deep learning workshop, 2015, .
 - [34] Snell J, Swersky K, Zemel R. Prototypical networks for few-shot learning[J]. Advances in Neural Information Processing Systems(NeurIPS), 2017, 30.
 - [35] Sung F, Yang Y, Zhang L, et al. Learning to compare: Relation network for few-shot learning[C]. The IEEE Conference on Computer Vision and Pattern Recognition(CVPR), 2018, 1199-1208.
 - [36] Finn C, Abbeel P, Levine S. Model-agnostic meta-learning for fast adaptation of deep networks[C]. International Conference on Machine Learning(ICML), 2017, 1126-1135.
 - [37] Zintgraf L, Shiarli K, Kurin V, et al. Fast context adaptation via meta-learning[C]. International Conference on Machine Learning(ICML), 2019, 7693-7702.
 - [38] Antoniou A, Edwards H, Storkey A. How to train your maml[C]. International Conference on Learning Representations(ICLR), 2018, .
 - [39] Ye H.-J, Chao W.-L. How to train your maml to excel in few-shot classification[J]. arXiv preprint arXiv:2106.16245, 2021.
 - [40] Ravi S, Larochelle H. Optimization as a model for few-shot learning[C]. International Conference on Learning Representations(ICLR), 2016, .
 - [41] Munkhdalai T, Yu H. Meta networks[C]. International Conference on Machine Learning(ICML), 2017, 2554-2563.
 - [42] Daniel K. Thinking, fast and slow[M]. , 2017.
 - [43] Patacchiola M, Bronskill J, Shysheya A, et al. Contextual squeeze-and-excitation for efficient few-shot image classification[J]. Advances in Neural Information Processing Systems(NeurIPS), 2022, 35: 36680-36692.
 - [44] Santoro A, Bartunov S, Botvinick M, et al. Meta-learning with memory-augmented neural networks[C]. International Conference on Machine Learning(ICML), 2016, 1842-1850.
 - [45] Chen W.-Y, Liu Y.-C, Kira Z, et al. A closer look at few-shot classification[J]. arXiv preprint arXiv:1904.04232, 2019.

- [46] Tian Y, Wang Y, Krishnan D, et al. Rethinking few-shot image classification: a good embedding is all you need?[C]. Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XIV 16, 2020, 266-282.
- [47] Triantafillou E, Zhu T, Dumoulin V, et al. Meta-dataset: A dataset of datasets for learning to learn from few examples[J]. arXiv preprint arXiv:1903.03096, 2019.
- [48] Requeima J, Gordon J, Bronskill J, et al. Fast and flexible multi-task classification using conditional neural adaptive processes[J]. Advances in Neural Information Processing Systems(NeurIPS), 2019, 32.
- [49] Bateni P, Goyal R, Masrani V, et al. Improved few-shot visual classification[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2020, 14493-14502.
- [50] Chen Y, Liu Z, Xu H, et al. Meta-baseline: Exploring simple meta-learning for few-shot learning[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2021, 9062-9071.
- [51] Hu S. X, Li D, Stühmer J, et al. Pushing the limits of simple pipelines for few-shot learning: External data and fine-tuning make a difference[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2022, 9068-9077.
- [52] Liu Y, Lee J, Zhu L, et al. A multi-mode modulator for multi-domain few-shot classification[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2021, 8453-8462.
- [53] Liu L, Hamilton W, Long G, et al. A universal representation transformer layer for few-shot image classification[J]. arXiv preprint arXiv:2006.11702, 2020.
- [54] Rizve M. N, Khan S, Khan F. S, et al. Exploring complementary strengths of invariant and equivariant representations for few-shot learning[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2021, 10836-10846.
- [55] Luo X, Wu H, Zhang J, et al. A closer look at few-shot classification again[C]. International Conference on Machine Learning(ICML), 2023, 23103-23123.
- [56] Wei J, Tay Y, Bommasani R, et al. Emergent abilities of large language models[J]. arXiv preprint arXiv:2206.07682, 2022.
- [57] Jia C, Yang Y, Xia Y, et al. Align: Scaling up visual and vision-language representation learning with noisy text supervision[J]. arXiv preprint arXiv:2102.05918, 2021, 4.
- [58] Oquab M, Darcet T, Moutakanni T, et al. DINOv2: Learning robust visual features without supervision[J]. arXiv preprint arXiv:2304.07193, 2023.
- [59] Bai Y, Geng X, Mangalam K, et al. Sequential modeling enables scalable learning for large vision models[J]. arXiv preprint arXiv:2312.00785, 2023.

- [60] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems(NeurIPS), 2022, 35: 24824-24837.
- [61] Kojima T, Gu S. S, Reid M, et al. Large language models are zero-shot reasoners[J]. Advances in Neural Information Processing Systems(NeurIPS), 2022, 35: 22199-22213.
- [62] Goldblum M, Reich S, Fowl L, et al. Unraveling meta-learning: Understanding feature representations for few-shot tasks[C]. International Conference on Machine Learning(ICML), 2020, 3607-3616.
- [63] Lee K, Maji S, Ravichandran A, et al. Meta-learning with differentiable convex optimization[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2019, 10657-10665.
- [64] Ye H.-J, Hu H, Zhan D.-C, et al. Few-shot learning via embedding adaptation with set-to-set functions[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2020, 8808-8817.
- [65] Zhang C, Cai Y, Lin G, et al. Deepemd: Few-shot image classification with differentiable earth mover's distance and structured classifiers[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2020, 12203-12213.
- [66] Luo X, Wei L, Wen L, et al. Rectifying the shortcut learning of background for few-shot learning[J]. Advances in Neural Information Processing Systems(NeurIPS), 2021, 34: 13073-13085.
- [67] Mangla P, Kumari N, Sinha A, et al. Charting the right manifold: Manifold mixup for few-shot learning[C]. The IEEE/CVF Winter Conference on Applications of Computer Vision(WACV), 2020, 2218-2227.
- [68] Kolesnikov A, Beyer L, Zhai X, et al. Big transfer (bit): General visual representation learning[C]. Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part V 16, 2020, 491-507.
- [69] Zhao N, Wu Z, Lau R. W, et al. What makes instance discrimination good for transfer learning?[J]. arXiv preprint arXiv:2006.06606, 2020.
- [70] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]. International Conference on Machine Learning(ICML), 2021, 10347-10357.
- [71] Chen X, Fan H, Girshick R, et al. Improved baselines with momentum contrastive learning[J]. arXiv preprint arXiv:2003.04297, 2020.

- [72] Li W.-H, Liu X, Bilen H. Universal representation learning from multiple domains for few-shot classification[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2021, 9526-9535.
- [73] Li W.-H, Liu X, Bilen H. Cross-domain few-shot learning with task-specific adapters[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2022, 7161-7170.
- [74] Xu C, Yang S, Wang Y, et al. Exploring efficient few-shot adaptation for vision transformers[J]. arXiv preprint arXiv:2301.02419, 2023.
- [75] Bronskill J, Gordon J, Requeima J, et al. Tasknorm: Rethinking batch normalization for meta-learning[C]. International Conference on Machine Learning(ICML), 2020, 1153-1164.
- [76] Xie J, Long F, Lv J, et al. Joint distribution matters: Deep brownian distance covariance for few-shot classification[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2022, 7972-7981.
- [77] Cowley B, Vinci G. Summary and discussion of: Brownian distance covariance[J]. Statistics Journal Club, 2014, 36: 825.
- [78] Feuerverger A. A consistent test for bivariate dependence[J]. International Statistical Review/Revue Internationale de Statistique, 1993, 419-433.
- [79] Sohl-Dickstein J. Neural network training makes beautiful fractals , .
- [80] Bergstra J, Bardenet R, Bengio Y, et al. Algorithms for hyper-parameter optimization[J]. Advances in Neural Information Processing Systems(NeurIPS), 2011, 24.
- [81] Bergstra J, Yamins D, Cox D. Making a science of model search: Hyperparameter optimization in hundreds of dimensions for vision architectures[C]. International Conference on Machine Learning(ICML), 2013, 115-123.
- [82] Allen-Zhu Z, Li Y. Towards understanding ensemble, knowledge distillation and self-distillation in deep learning[J]. arXiv preprint arXiv:2012.09816, 2020.
- [83] Wang L, Ghosh D, Diaz M. G, et al. Wisdom of the ensemble: Improving consistency of deep learning models[J]. Advances in Neural Information Processing Systems(NeurIPS), 2020, 33: 19750-19761.
- [84] Luo X, Gao L, Song J. Benchmarking few-shot transferability of pre-trained models with improved evaluation protocols[J]. , .
- [85] Xu Z.-Q. J, Zhang Y, Luo T, et al. Frequency principle: Fourier analysis sheds light on deep neural networks[J]. arXiv preprint arXiv:1901.06523, 2019.

-
- [86] Agarap A. F. Deep learning using rectified linear units (relu)[J]. arXiv preprint arXiv:1803.08375, 2018.
- [87] Cheng H, Yang S, Zhou J. T, et al. Frequency guidance matters in few-shot learning[C]. The IEEE/CVF International Conference on Computer Vision(ICCV), 2023, 11814-11824.
- [88] Shen Z, Liu Z, Qin J, et al. Partial is better than all: Revisiting fine-tuning strategy for few-shot learning[C]. The AAAI Conference on Artificial Intelligence(AAAI), 2021, 9594-9602.
- [89] Cai H, Gan C, Zhu L, et al. Tinytl: Reduce memory, not parameters for efficient on-device learning[J]. Advances in Neural Information Processing Systems(NeurIPS), 2020, 33: 11285-11297.
- [90] Zaken E. B, Ravfogel S, Goldberg Y. Bitfit: Simple parameter-efficient fine-tuning for transformer-based masked language-models[J]. arXiv preprint arXiv:2106.10199, 2021.
- [91] Picek L, Šulc M, Matas J, et al. Danish fungi 2020-not just another image recognition dataset[C]. The IEEE/CVF Winter Conference on Applications of Computer Vision(WACV), 2022, 1525-1535.
- [92] Kumar A. D. Novel deep learning model for traffic sign detection using capsule networks[J]. arXiv preprint arXiv:1805.04424, 2018.
- [93] Hu E. J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models[J]. arXiv preprint arXiv:2106.09685, 2021.
- [94] Zhao J, Zhang Z, Chen B, et al. Galore: Memory-efficient llm training by gradient low-rank projection[J]. arXiv preprint arXiv:2403.03507, 2024.
- [95] Liu J, Xiao G, Li K, et al. Bitdelta: Your fine-tune may only be worth one bit[J]. arXiv preprint arXiv:2402.10193, 2024.
- [96] Wu H, Flierl M. Vector quantization-based regularization for autoencoders[C]. The AAAI Conference on Artificial Intelligence(AAAI), 2020, 6380-6387.
- [97] AskariHemmat M, Hemmat R. A, Hoffman A, et al. Qreg: On regularization effects of quantization[J]. arXiv preprint arXiv:2206.12372, 2022.
- [98] Yao H, Zhang R, Xu C. Visual-language prompt tuning with knowledge-guided context optimization[C]. The IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), 2023, 6757-6767.
- [99] Min S, Lyu X, Holtzman A, et al. Rethinking the role of demonstrations: What makes in-context learning work?[J]. arXiv preprint arXiv:2202.12837, 2022.
- [100] Oswald Jvon , Niklasson E, Schlegel M, et al. Uncovering mesa-optimization algorithms in transformers[J]. arXiv preprint arXiv:2309.05858, 2023.

- [101] Xie S. M, Raghunathan A, Liang P, et al. An explanation of in-context learning as implicit bayesian inference[J]. arXiv preprint arXiv:2111.02080, 2021.
- [102] Liu N. F, Lin K, Hewitt J, et al. Lost in the middle: How language models use long contexts[J]. Transactions of the Association for Computational Linguistics, 2024, 12: 157-173.
- [103] Wei J, Hou L, Lampinen A, et al. Symbol tuning improves in-context learning in language models[J]. arXiv preprint arXiv:2305.08298, 2023.
- [104] Chung H. W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models[J]. arXiv preprint arXiv:2210.11416, 2022.
- [105] Wang Y, Mishra S, Alipoormolabashi P, et al. Super-naturalinstructions: Generalization via declarative instructions on 1600+ nlp tasks[J]. arXiv preprint arXiv:2204.07705, 2022.
- [106] Wei J, Bosma M, Zhao V. Y, et al. Finetuned language models are zero-shot learners[J]. arXiv preprint arXiv:2109.01652, 2021.
- [107] Jiang H, Wu Q, Lin C.-Y, et al. LlmLingua: Compressing prompts for accelerated inference of large language models[J]. arXiv preprint arXiv:2310.05736, 2023.
- [108] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]. European Conference on Computer Vision(ECCV), 2020, 213-229.
- [109] Zhu X, Su W, Lu L, et al. Deformable detr: Deformable transformers for end-to-end object detection[J]. arXiv preprint arXiv:2010.04159, 2020.
- [110] Wang H, Vasu P. K. A, Faghri F, et al. Sam-clip: Merging vision foundation models towards semantic and spatial understanding[J]. arXiv preprint arXiv:2310.15308, 2023.
- [111] Otsu N, et al. A threshold selection method from gray-level histograms[J]. Automatica, 1975, 11(285-296): 23-27.
- [112] Belrose N, Furman Z, Smith L, et al. Eliciting latent predictions from transformers with the tuned lens[J]. arXiv preprint arXiv:2303.08112, 2023.
- [113] Anthropic . Model card and evaluations for claude models, 2023.
- [114] Wu T, Luo L, Li Y.-F, et al. Continual learning for large language models: A survey[J]. arXiv preprint arXiv:2402.01364, 2024.